



IA Generativa

Visão Geral


&

Fundamentos de IA Generativa

Principais paradigmas de aprendizado de máquina

- Quais são eles?
- Quais são suas principais características?

Aprendizado de máquina



Principais paradigmas de aprendizado de máquina

- **Supervisionado** (tem rótulos): Classificação, regressão.
- **Não Supervisionado** (não tem rótulos): Agrupamento (*clustering*), redução de dimensionalidade, detecção de anomalias, estimação de densidade, geração de dados sintéticos, etc.
- **Reforço**: O agente aprende interagindo com o ambiente.

Aprendizado por reforço




FIGURE 2. The perception-action-learning loop. At time t , the agent receives state s_t from the environment. The agent uses its policy to choose an action a_t . Once the action is executed, the environment transitions a step, providing the next state, s_{t+1} , as well as feedback in the form of a reward, r_{t+1} . The agent uses knowledge of state transitions, of the form $(s_t, a_t, s_{t+1}, r_{t+1})$, to learn and improve its policy.

K. Arulkumaran et al., "Deep Reinforcement Learning: A Brief Survey," *IEEE Signal Process. Mag.*, vol. 34, no. 6, pp. 26–38, Nov. 2017.




Fig. 1 Example of a simple grid world where RL techniques can be used to optimally reach a goal state from any starting position

E. F. Morales et al., "A survey on deep learning and deep reinforcement learning in robotics with a tutorial on deep reinforcement learning," *Intell. Serv. Robot.*, vol. 14, no. 5, pp. 773–805, Nov. 2021.

Aprendizado por reforço



Kohl and Stone, 2004




Ng et al, 2004



Tedrake et al, 2005



Kober and Peters, 2009



Mnih et al, 2015
(A3C)



Silver et al, 2014
(DPG)
Lillicrap et al, 2015
(DDPG)



Schulman et al,
2016 (TRPO + GAE)




Levine*, Finn*, et
al, 2016
(GPS)



Silver*, Huang*, et
al, 2016
(AlphaGo)


John Schulman & Pieter Abbeel – OpenAI + UC Berkeley





[DeepMind Atari](#)
[DeepMind AlphaGo](#)
[DeepMind AlphaStar](#)

<https://simons.berkeley.edu/sites/default/files/docs/6453/201703xxsimons-representations-deep-rl.pdf>

Aprendizado supervisionado




Aprendizado não-supervisionado




Andriy Burkov, The Hundred-Page Machine Learning Book, 2019.

<https://www.linkedin.com/pulse/cluster-analysis-marketing-techniques-methods-use-cases-chetan-yadav>


<https://machinelearninggeek.com/text-clustering-clustering-news-articles/>



<https://www.geeksforgeeks.org/data-science/dimensionality-reduction-techniques/>



Anomaly Detection



<https://pyimagesearch.com/2020/01/20/intro-to-anomaly-detection-with-opencv-computer-vision-and-scikit-learn/>

O que é IA Generativa?



Amostras da distribuição dos dados

Treinamento



Modelo generativo




Amostragem




Modelos de IA que criam *novos* dados (textos, imagens, áudio, etc.).

Adaptado de K. Kreis, R. Gao e A. Vahdat. CVPR 2022 Tutorial: Denoising Diffusion-based Generative Modeling: Foundations and Applications. Tutorial at the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), <https://cvpr2022-tutorial-diffusion-models.github.io/>, 2022.




<https://openai.com/>





<https://www.visualcapitalist.com/threads-100-million-users/>


<https://stability.ai/>



<https://www.udio.com/>



<https://x.ai/news/grok-4-5>



<https://suno.com/home>

Alguns modelos e empresas

ANTHROPIC

 Claude


stability.ai



ChatGPT
Sora



Exemplos de tarefas




Adaptado de S. Bengio et al., "Advancements in Generative AI: A Comprehensive Review of GANs, GPT, Autoencoders, Diffusion Model, and Transformers," IEEE Access, vol. 12, no. April, pp. 69812–69837, 2024.

Uma breve história (linha do tempo...)

- Exemplos de modelos generativos clássicos

- Modelos de misturas Gaussianas (GMM)
- Modelos ocultos de Markov (HMM)
- Máquinas de Boltzmann (BM)



Y. Cao et al., "A Comprehensive Survey of AI-Generated Content (AIGC): A History of Generative AI from GAN to ChatGPT," J. Acron, vol. 37, no. 111, Mar. 2023.

Evolução das Generative Adversarial Networks (GANs)



Evolução das Generative Adversarial Networks (GANs)



Por que modelos generativos?

- As redes neurais que aprendem apenas a classificar (isto é, modelos discriminativos que modelam $p(y|x)$) podem falhar diante de pequenas perturbações (ruídos).



x
“panda”
57.7% confidence

$+ .007 \times$



$\text{sign}(\nabla_x J(\theta, x, y))$
“nematode”
8.2% confidence

$=$




$x + \epsilon \text{sign}(\nabla_x J(\theta, x, y))$
“gibbon”
99.3 % confidence

L. J. Goodfellow, J. Shlens, and C. Szegedy, “Explaining and Harnessing Adversarial Examples,” pp. 1–11, Dec. 2014.

Por que modelos generativos?


Gráfico de dispersão dos dados



Por que modelos generativos?

Abordagem discriminativa

$p(\textit{classe 1} | x = \mathbf{X})$ é alta
=
decisão certa!



Por que modelos generativos?

$$p(\mathbf{x}, y) = p(y|\mathbf{x})p(\mathbf{x})$$

Abordagem generativa

$p(\text{classe } 1 | \mathbf{x} = \mathbf{X})$ é alta


e

$p(\mathbf{x} = \mathbf{X})$ é baixa

=

Incerteza na decisão!

$(p(\mathbf{x} = \mathbf{X}, y = \text{classe } 1))$ é baixa)



Por que modelos generativos?

- Para realizar tomadas de decisão é essencial que um sistema de IA “**entenda**” o mundo e seja capaz de quantificar incertezas, reconhecendo quando se depara com algo novo.

Modelos generativos vs. modelos discriminativos


- Modelos discriminativos

- Estimam a probabilidade condicional $p(y|x)$, isto é, a probabilidade de um rótulo y dado uma observação x .
- Modelos discriminativos aprendem diretamente a decidir a classe de um objeto, mas podem atribuir alta certeza em regiões desconhecidas.


- Modelos gerativos

- Estimam a distribuição conjunta dos dados $p(x)$ (ou $p(x, y)$).
- Permitem identificar se um ponto é improvável ou fora da distribuição conhecida, atribuindo incerteza à decisão.
- Aprendem a modelar a distribuição dos dados e podem fazer amostragem

- Discriminative Model



- Generative Model



<https://developers.google.com/machine-learning/gan/generative?hl=pt-br>

Por que modelos generativos?

- Vantagens de conhecer $p(x)$
 - Detectar se um objeto nunca foi observado antes.
 - Fundamentar as decisões de forma mais robusta.
 - Avaliar incertezas no ambiente.
 - Permitir aprendizagem ativa (por exemplo, perguntando sobre rótulos de dados incomuns).
 - **Possibilitar a síntese (geração) de novos dados.**
- Fatorações na modelagem generativa

$$p(x, y) = p(y|x)p(x)$$

$$p(x, y) = p(x|y)p(y)$$

Por que modelos generativos?

- Aplicações


- Modelos gerativos podem ser usados em diversas áreas, desde análise de texto, análise de imagens, análise de áudio, e análise de grafos, até aprendizado ativo (identificar exemplos incertos - baixa probabilidade $p(x)$ - para solicitar rótulos), aprendizado por reforço (gerar estados prováveis para guiar a ação de um agente), e aplicações médicas.

Die durch lebhaftes Farbenmischungs ziemlich auffallende Art
ist besonders durch die Mischung der hellen Blauviolettfarbe mit
Auffassung in eine ungewöhnliche Färbung, wenn das An-
sehen einer kalten Lichtung ist und meistens ausgedehnten
hellen Lichtblau eine ungewöhnliche. Klarer wie bei dem
Fuchsen D. Gualdo drückt nicht sich eine nur stärker erhellte
Lagerung, die etwas innerhalb der Klarheit liegt, so wie
die Mitte. Im Gegensatz zu dieser Art ist Kopf und Halschil
in viel geringer Ausdehnung dicht. Innerhalb, so es schweben
Hintergrund und besonders die viel weiniger ausgeprägten Beina-
schichten mehr Raum für die Beleuchtung übrig lassen. Diese
ist sehr dunkel, auf dem Halschil zwischen dem kalten Hals
und auf der Seite schweben klarer und weißer, der dünne
Teil des Kopfes, wenn eine einzelne Bewegung der glänzenden
Hintergrund des Fuchsen und der Beina meistens nur Beina-
schichten vordrückt. Das Grundmischungs der Färbung ist daher
sehr dunkel, fast schwarz, die sehr schwebende weinige Beina
der D. G. ist sehr ungewöhnlich begrenzt, teils in die Beina von
Fuchsen aufsteigt, während der Beina schweben von dem der
Hintergrund schweben. Zwischen mit ihrer sehr begrenzten, kalten
Beina meistens dunkel. Von D. Elspet Fuchsen mit Mischung
Fuchsen meistens sich ungewöhnlich. Abgesehen von der Zeichnung,
durch die bei demselben Art ganz isolieren eine von aus-
gedehnten Beina schweben der Halschil. Bei D. alternans
denn, ist die kalte Halschil meistens tief dunkel und die
Hintergrund der Färbung sehr schweben, zwischen falls bei
denn, ist die Färbung

Textos




Áudios



Grafos



Vídeos




Imagens

Modelagem generativa

1. Temos um conjunto de dados X .
2. Assumimos que os dados observados foram gerados de acordo com uma distribuição desconhecida P_{dados} .
3. Nosso objetivo é construir um modelo generativo $P_{\text{modelo}} = P_{\theta}$ que imita/emula P_{dados} .
4. Dessa forma podemos gerar dados sintéticos a partir de P_{modelo} .




$$\mathbf{x}_i \sim P_{\text{data}} \\ i = 1, 2, \dots, n$$




Família de modelos

Modelagem generativa

Exemplo: modelos de variáveis latentes



Geração aleatória de imagem ($x^* = G(z)$)



Entrada aleatória (z)





Imagem gerada (x^*)

Geração condicional de imagem ($x^* = G(z, c)$)




Geração condicional de imagem ($x^* = G(z, T(texto))$)

Touro da raça nelore
bebendo água no açude
durante o pôr do sol.

Prompt

Codificador de texto T



Entrada aleatória (z)


Modelo
Generativo
 $G(z, T(texto))$



Imagem gerada (x^*)

Objetivos da modelagem generativa

• Geração de dados sintéticos



(a) Teddy bears swimming at the Olympics 400m Butterfly event.



(b) A cute corgi lives in a house made out of sushi.




(c) A cute sloth holding a small treasure chest. A bright golden glow is coming from the chest.



A portrait photo of a kangaroo wearing an orange hoodie and blue sunglasses standing on the grass in front of the Sydney Opera House holding a sign on the chest that says Welcome Friends!

Objetivos da modelagem generativa

Estimação de densidade de probabilidade



Imputação

Data sample	Variables			Missing values replaced by means		
	A	B	C	A	B	C
1	6	6	NA	2	6	7.5
2	NA	6	0	9	6	0
3	NA	6	NA	9	6	7.5
4	10	10	10	10	10	10
5	10	10	10	10	10	10
6	10	10	10	10	10	10
Average	9	8	7.5	9	8	7.5




Objetivos da modelagem generativa

- Interpolação do espaço latente




Objetivos da modelagem generativa

- Aritmética no espaço latente



Simon J.D. Prince. Understanding Deep Learning, The MIT Press, 2023.



B. Ghoggh et al., "Generative Adversarial Networks and Adversarial Autoencoders: Tutorial and Survey," Nov. 2021.

IA Generativa

- O que torna um modelo generativo bom?


IA Generativa

- O que torna um modelo generativo bom?
 - Amostragem eficiente
 - Amostragem de alta qualidade
 - Amostragem diversa
 - Espaço latente
 - Bem comportado: mudanças suaves em z correspondem a mudanças suaves em x
 - Desentrelaçado: manipular cada dimensão de z deve corresponder a alterações em propriedades interpretáveis dos dados.
 - Computação eficiente da verossimilhança


IA Generativa

- Tipos de modelos generativos

Unimodal



Multimodal



Taxonomia (em relação à modelagem de $p(x)$)

Utilização de
aprendizado
profundo!

Modelos Generativos

Densidade
explícita

Densidade
aproximada

VAEs

EBMs

DMs



Densidade
tratável

ARMs

NFs


Densidade
implícita

GANs



Modelos generativos

1. Modelos baseados em energia (EBMs)
2. Generative adversarial networks (GANs)
3. Variational autoencoders (VAEs)
4. Modelos baseados em fluxo
5. Modelos de difusão
6. Modelos auto-regressivos (ARMs)



Tipos de modelos gerativos profundos

- Há quatro grupos principais para estruturar $p(x)$:
 - Modelos autoregressivos
 - Modelos baseados em fluxo
 - Modelos de variáveis latentes
 - Modelos baseados em energia
- Redes neurais profundas geralmente são utilizadas para parametrizar esses modelos, graças à sua flexibilidade e poder de representação.
- **Observação:** essa classificação serve apenas como guia para navegar no estudo de modelos gerativos; há modelos que podem se encaixar em mais de uma categoria.

Referências

- Simon J. D. Prince. Understanding Deep Learning, The MIT Press, 2023. [capítulo 14]
 - disponível em: <https://udlbook.github.io/udlbook/>
- Kevin P. Murphy. Probabilistic Machine Learning: Advanced Topics, MIT Press, 2023. [capítulo 20]
 - disponível em: <https://probml.github.io/pml-book/book2.html>

Slides construídos em parte com base nos livros supracitados, os quais estão disponibilizados publicamente pelos seus respectivos autores.

- Jakub M. Tomczak. Deep Generative Modeling, Springer, 2024. [capítulo 1]