

Avaliação de qualidade em modelos generativos - parte 1

Inteligência Artificial Generativa

Dimensões para a avaliação de um modelo generativo

- ① Amostragem
 - Eficiência
 - Qualidade
 - Diversidade
- ② Capacidade de generalização
- ③ Espaço latente bem comportado
- ④ Espaço latente desentrançado
- ⑤ Cálculo da verossimilhança eficiente

Model	Efficient	Sample quality	Coverage	Well-behaved latent space	Disentangled latent space	Efficient likelihood
GANs	✓	✓	✗	✓	?	n/a
VAEs	✓	✗	?	✓	?	✗
Flows	✓	✗	?	✓	?	✓
Diffusion	✗	✓	?	✗	✗	✗

- ① Avaliação baseada na verossimilhança
- ② Distâncias e divergências no espaço de características
 - *Inception Score* (IS)
 - *Fréchet inception distance* (FID)
- ③ Medidas envolvendo precisão e revocação
 - Precisão e revocação de variedades (*Manifold precision and recall*)
- ④ Testes estatísticos
- ⑤ Avaliação humana

Definição


- Mede o grau de incerteza (aleatoriedade) de uma variável aleatória.
- Suponha uma variável aleatória discreta A com suporte $S_A = \{a_1, a_2, \dots, a_v\}$.
- Se a probabilidade de observar cada valor é $p_1, p_2, \dots, p_v$, então a entropia de A é:

$$\mathbb{H}(A) = - \sum_i p_i \log_2 p_i$$

- Quantidade de informação (ou surpresa): $\mathbb{I}(a_i) = -\log_2 p_i$
- Usando logaritmos na base 2, a entropia é medida em **bits**.
- É assumido que $0 \cdot \log_2(0) = 0$.

Entropia (Revisão) II

Exemplo: Entropia de uma variável aleatória com distribuição Bernoulli.



Avaliação baseada em Versossimilhança I

Podemos medir quão perto o modelo q está da distribuição real p utilizando a divergência de Kullback-Leibler (KL):

$$\mathbb{KL}(p \parallel q) = \mathbb{E}_{\mathbf{x} \sim p} \left[\log \frac{p(\mathbf{x})}{q(\mathbf{x})} \right] = -\mathbb{H}(p) + \mathbb{H}_{ce}(p, q)$$

- $\mathbb{H}(p)$: entropia de p (constante).
- $\mathbb{H}_{ce}(p, q)$: entropia cruzada.

Podemos aproximar $p(\mathbf{x})$ pela distribuição empírica e então avaliar a entropia cruzada como o negativo do logaritmo da verossimilhança:

$$\text{NLL} = -\frac{1}{N} \sum_{n=1}^N \log q(\mathbf{x}_n)$$

Para a avaliação, o NLL deve ser calculado em um **conjunto de teste**.

Cálculo da Log-Verossimilhança

- Modelos discretos (ex.: **modelos de linguagem**) $\rightarrow$ NLL computada diretamente.
- **Perplexidade:**

$$\text{perplexidade} = 2^H, \quad H = \text{NLL}$$

- H : entropia cruzada ou NLL.
- Valores **menores** são melhores.

- Podemos comparar modelos probabilísticos medindo sua **verossimilhança** em um **conjunto de teste**.
- **Por que em um conjunto de teste?**

Sobreaajuste [*Overfitting*]

- Medir a verossimilhança no **conjunto de treinamento** é ineficaz, porque um modelo pode atribuir probabilidade muito alta nos pontos do **conjunto de treinamento** e muito baixa em pontos fora do conjunto de treinamento.
 - Resultado:
verossimilhança de **treinamento** alta
e
verossimilhança de **teste** baixa
⇒ memorização.

Verossimilhança no conjunto de teste

1 Generalização

Mede quão bem o modelo explica *exemplos nunca vistos*.

A verossimilhança deve permanecer alta se o modelo capturou a estrutura dos dados e não só os memorizou.

2 Cobertura

A densidade deve distribuir massa de probabilidade por todo o suporte plausível.

Se ela se concentra demais apenas em um subconjunto do treinamento, ela precisa atribuir probabilidades menores em outras regiões.

Verossimilhança por tipo de modelo:

- **GANs:** não definem densidade $p(\mathbf{x})$. Portanto, a métrica de verossimilhança não se aplica.
- **VAEs e modelos de difusão:** calcula-se um limite inferior (ELBO), que é uma aproximação.
- **Normalizing flows:** cálculo exato e eficiente da verossimilhança.
- **Modelos autoregressivos:** verossimilhança exata, porém avaliada de forma sequencial.


Inception Score (IS) I

- Métrica para avaliar a qualidade e diversidade de imagens geradas por modelos generativos.
- Utiliza um modelo pré-treinado (ex.: *Inception-v3*) para calcular distribuições condicionais e marginais dos rótulos.
- Captura dois aspectos principais:
 - **Qualidade:** Imagens geradas devem ser reconhecíveis.
 - **Diversidade inter-classe:** Conjunto de imagens deve ser diverso entre as classes.

Inception Score: T. Salimans et. al, "Improved Techniques for Training GANs," Adv. Neural Inf. Process. Syst., 2016.

Inception Score (IS) II

Inception-v3





Inception-v3: C. Szegedy et al., "Rethinking the Inception Architecture for Computer Vision," 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), Las Vegas, NV, USA, 2016, pp. 2818-2826.

Figura de: O. Iparraguirre-Villanueva et al., "Convolutional Neural Networks with Transfer Learning for Pneumonia Detection" International Journal of Advanced Computer Science and Applications(IJACSA), 13(9), 2022.

Inception Score (IS) III

$$IS = \exp \left(\mathbb{E}_{p_{\theta}(\mathbf{x})} [\text{KL}(p(y|\mathbf{x}) || p_{\theta}(y))] \right)$$

- $p(y|\mathbf{x})$: Distribuição condicional dos rótulos (modelo discriminativo).
- $p_{\theta}(\mathbf{x})$: Distribuição marginal dos dados (modelo generativo).
- $p_{\theta}(y) = \mathbb{E}_{p_{\theta}(\mathbf{x})} [p(y|\mathbf{x})]$: Distribuição marginal dos rótulos (diversidade inter-classe).



Inception Score (IS) IV

Relação entre o *Inception Score* e a entropia:

$$\begin{aligned}\ln(\text{IS}) &= \ln \left\{ \exp \left(\mathbb{E}_{p_{\theta}(\mathbf{x})} [\text{KL}(p(y|\mathbf{x}) \parallel p_{\theta}(y))] \right) \right\} \\&= \mathbb{E}_{p_{\theta}(\mathbf{x})} [\text{KL}(p(y|\mathbf{x}) \parallel p_{\theta}(y))] \\&= \mathbb{E}_{p_{\theta}(\mathbf{x})} \left[\mathbb{E}_{p(y|\mathbf{x})} \left[\ln \frac{p(y|\mathbf{x})}{p_{\theta}(y)} \right] \right] \\&= \mathbb{E}_{p_{\theta}(\mathbf{x})} \left[\mathbb{E}_{p(y|\mathbf{x})} [\ln p(y|\mathbf{x})] - \mathbb{E}_{p(y|\mathbf{x})} [\ln p_{\theta}(y)] \right] \\&= \mathbb{E}_{p_{\theta}(\mathbf{x})} [-\mathbb{H}(p(y|\mathbf{x}))] - \mathbb{E}_{p_{\theta}(\mathbf{x})} \left[\mathbb{E}_{p(y|\mathbf{x})} [\ln p_{\theta}(y)] \right] \\&= \mathbb{E}_{p_{\theta}(\mathbf{x})} [-\mathbb{H}(p(y|\mathbf{x}))] - \mathbb{E}_{p_{\theta}(\mathbf{x})} \left[\sum_y p(y|\mathbf{x}) \ln p_{\theta}(y) \right] \\&= \mathbb{E}_{p_{\theta}(\mathbf{x})} [-\mathbb{H}(p(y|\mathbf{x}))] - \sum_y \underbrace{\mathbb{E}_{p_{\theta}(\mathbf{x})} [p(y|\mathbf{x})]}_{p_{\theta}(y)} \ln p_{\theta}(y) \\&= \mathbb{E}_{p_{\theta}(\mathbf{x})} [-\mathbb{H}(p_{\theta}(y|\mathbf{x}))] - \sum_y p_{\theta}(y) \ln p_{\theta}(y) \\&= \boxed{\mathbb{H}(p_{\theta}(y)) - \mathbb{E}_{p_{\theta}(\mathbf{x})} [\mathbb{H}(p(y|\mathbf{x}))]}\end{aligned}$$

- $\mathbb{H}(p_{\theta}(y)) = \mathbb{H}(Y)$: entropia marginal de Y .
- $\mathbb{H}(p(y|\mathbf{x})) = \mathbb{H}(Y|\mathbf{X} = \mathbf{x})$: entropia condicional de Y dado $\mathbf{X} = \mathbf{x}$.
- $\mathbb{H}(Y|\mathbf{X}) = \mathbb{E}_{p_{\theta}(\mathbf{x})} [\mathbb{H}(Y|\mathbf{X} = \mathbf{x})]$: entropia condicional de Y dado $\mathbf{X}$.

Inception Score (IS) V

Cálculo da IS:

- 1 **Distribuições condicionais:** Usar o modelo pré-treinado *Inception-v3* para calcular $p(y|\mathbf{x})$ para cada imagem gerada $\mathbf{x}$.
- 2 **Distribuição marginal:**

$$p_{\theta}(y) = \int p(y|\mathbf{x})p_{\theta}(\mathbf{x})d\mathbf{x} = \mathbb{E}_{p_{\theta}(\mathbf{x})} [p(y|\mathbf{x})]$$
$$\approx \hat{p}_{\theta}(y) = \frac{1}{N} \sum_{i=1}^N p(y|\mathbf{x}_i), \quad \mathbf{x}_i \sim p_{\theta}(\mathbf{x})$$

Em particular, para cada classe $c \in \{1, \dots, K\}$:

$$\hat{p}_{\theta}(y = c) = \frac{1}{N} \sum_{i=1}^N p(y = c | \mathbf{x}_i)$$

Inception Score (IS) VI

3 Divergência KL para o dado sintético $\mathbf{x}_i$:

$$\begin{aligned}\mathbb{KL}(p(y|\mathbf{x}_i) \parallel \hat{p}_{\theta}(y)) &= \sum_y p(y|\mathbf{x}_i) \log \frac{p(y|\mathbf{x}_i)}{\hat{p}_{\theta}(y)} \\ &= \sum_{c=1}^K p(y=c|\mathbf{x}_i) \ln \frac{p(y=c|\mathbf{x}_i)}{\hat{p}_{\theta}(y=c)}\end{aligned}$$

4 Média das KL:

$$\mathbb{E}_{p_{\theta}(\mathbf{x})} [\mathbb{KL}(p(y|\mathbf{x}) \parallel \hat{p}_{\theta}(y))] \approx \frac{1}{N} \sum_{i=1}^N \mathbb{KL}(p(y|\mathbf{x}_i) \parallel \hat{p}_{\theta}(y)), \quad \mathbf{x}_i \sim p_{\theta}(\mathbf{x})$$

5 Exponencial:

$$\text{IS} = \exp \left(\frac{1}{N} \sum_{i=1}^N \mathbb{KL}(p(y|\mathbf{x}_i) \parallel \hat{p}_{\theta}(y)) \right)$$

Inception Score (IS) VII


Valores de IS mais altos são melhores ($\uparrow$ max-ótimo)

- O *Inception Score* captura dois aspectos principais de um modelo generativo:
 - **Qualidade das imagens:**
Baixa entropia condicional $p(y|\mathbf{x})$ indica imagens de alta qualidade, bem reconhecíveis.
 - **Diversidade inter-classe das imagens:**
Alta entropia marginal $p_{\theta}(y)$ indica que o modelo gera imagens variadas que cobrem várias classes.
- Pontuações maiores de IS indicam melhor equilíbrio entre qualidade e diversidade.

Mas qual a limitação do IS?


Inception Score (IS) IX

Problema: Modelos generativos com boa (alta) pontuação IS $\rightarrow$ amostras são visualmente realistas mas podem carecer de **diversidade intra-classe**.



Data

Model



Kevin P. Murphy. Probabilistic Machine Learning: Advanced Topics, The MIT Press, 2023.

Inception Score (IS) X

- **Vantagens:**

- Simples de calcular.
- Captura aspectos de qualidade e diversidade das imagens geradas.


- **Limitações:**

- **Sensibilidade ao conjunto de dados:** O modelo pré-treinado (ex.: *Inception-v3*) pode não representar bem as características dos dados gerados, especialmente se os dados gerados forem fora do domínio do conjunto de dados *ImageNet*.
- **Dependência do classificador:** A métrica depende do desempenho do classificador; treinar o mesmo modelo pode gerar valores consideravelmente diferentes.

Fréchet inception distance (FID) I

- Métrica para avaliar a qualidade de imagens sintetizadas por modelos generativos.
- Compara a distribuição das imagens reais e das geradas.
 - Aproxima ambas as distribuições como distribuições Gaussianas multivariadas no espaço de características de um classificador pré-treinado (ex.: espaço das ativações de uma camada profunda da rede *Inception-v3*).
 - Baseia-se na distância de Fréchet entre estas duas distribuições Gaussianas.

Fréchet inception distance (FID) II



Adaptado de T. Kynkäänniemi et al., "The Role of ImageNet Classes in Fréchet Inception Distance," 11th Int. Conf. Learn. Represent. ICLR 2023, Feb. 2023.

Fréchet inception distance (FID) III

- Definição:

$$\text{FID} = \|\boldsymbol{\mu}_g - \boldsymbol{\mu}_r\|_2^2 + \text{tr}(\boldsymbol{\Sigma}_r + \boldsymbol{\Sigma}_g - 2(\boldsymbol{\Sigma}_r \boldsymbol{\Sigma}_g)^{1/2})$$

- $\boldsymbol{\mu}_g, \boldsymbol{\Sigma}_g$: Média e matriz de covariância das imagens geradas.
- $\boldsymbol{\mu}_r, \boldsymbol{\Sigma}_r$: Média e matriz de covariância das imagens reais.
- Valores de FID menores são melhores ($\downarrow$ min-ótimo)


Fréchet inception distance (FID) IV

FID leva em consideração a **diversidade intra-classe**.



Data

Model



Kevin P. Murphy. Probabilistic Machine Learning: Advanced Topics, The MIT Press, 2023.

Fréchet inception distance (FID) V

Cálculo do FID

1 Extração de Características:

- Propagar as imagens (reais e geradas) por classificador pré-treinado até uma dada camada profunda.

2 Cálculo das Estatísticas: (a representa o vetor de características)

$$\begin{aligned}\mu_g &= \frac{1}{m} \sum_{i=1}^m a_i^{(g)}, & \Sigma_g &= \frac{1}{m} \sum_{i=1}^m (a_i^{(g)} - \mu_g)(a_i^{(g)} - \mu_g)^\top \\ \mu_r &= \frac{1}{n} \sum_{i=1}^n a_i^{(r)}, & \Sigma_r &= \frac{1}{n} \sum_{i=1}^n (a_i^{(r)} - \mu_r)(a_i^{(r)} - \mu_r)^\top\end{aligned}$$

3 Cálculo da distância de Fréchet:

$$\text{Termo da Média: } \|\mu_g - \mu_r\|_2^2$$

$$\text{Termo da Covariância: } \text{tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$

- Limitações

- **Assunção Gaussiana:** Supõe distribuições Gaussianas para as características, o que pode não ser válido para dados complexos.
- **Dependência de modelos pré-treinados:** Resultados podem variar dependendo do modelo e camada utilizados.
- **Sensibilidade ao Tamanho da Amostra:** Valores do FID podem variar consideravelmente dependendo do número de amostras utilizadas.
- **Falta de Interpretabilidade:** Não distingue se um FID alto é devido à baixa diversidade, baixa qualidade, ou ambos.



Simon J. D. Prince.

Understanding Deep Learning.

The MIT Press, 2023.

[Capítulo 14]

Disponível em: <https://udlbook.github.io/udlbook>



Kevin P. Murphy.

Probabilistic Machine Learning: Advanced Topics.

MIT Press, 2023.

[Capítulo 20]

Disponível em: <http://probml.github.io/book2>

Slides construídos com base nos livros supracitados, os quais estão disponibilizados publicamente por seus respectivos autores.