



IA Generativa

Avaliação de Qualidade em Modelos Generativos – parte 2

Precisão e Revocação de Variedades

Recapitulação

- FID mede a distância entre as distribuições dos dados reais e dos dados sintetizados pelo modelo generativo.
- O que um FID **elevado** (indesejável) indica?
 - Que o modelo não é capaz de gerar dados de alta qualidade?
 - Que o modelo não é capaz de gerar dados diversos?

Recapitulação

- **Problema:** FID avalia conjuntamente a qualidade e a diversidade das amostras, sendo incapaz de isolar esses fatores.
- Para desentrançar esses fatores, podemos considerar a **sobreposição** entre a variedade (*manifold*) dos dados reais e a variedade dos dados sintetizados pelo modelo generativo.
 - Variedade dos dados reais: subconjunto do espaço dos dados onde se encontram os exemplos reais.
 - Variedade dos dados gerados: subconjunto do espaço dos dados onde se encontram as amostras geradas.
- Vamos computar **precisão** e **revocação** para mensurar a **sobreposição** dessas variedades.

Revisão: métricas para classificação

- Matriz de confusão (M)
 - Alternativa para visualizar desempenho de classificador.
 - Mostra o número de predições corretas e incorretas em cada classe: pode-se observar quais classes o algoritmo de aprendizado de máquina tem maior dificuldade em classificar.
 - Em um problema de classificação com k classes: $M = [m_{ij}]_{k \times k}$

		Classe predita		
		C_1	C_2	C_3
		C_1	C_2	C_3
Classe verdadeira	C_1	11	1	3
	C_2	1	4	0
	C_3	2	1	6

- **Linhas:** classes verdadeiras
- **Colunas:** classes preditas pelo classificador
- Elemento m_{ij} : número de exemplos da classe verdadeira C_i classificados como pertencentes à classe C_j
- Diagonal da matriz: acertos do classificador
- Demais elementos: erros cometidos pelo classificador

Revisão: métricas para classificação binária

Seja um problema com duas classes: + e -

Matriz de confusão:

		Classe Preditada	
		+	-
Classe Verdadeira	+	VP	FN
	-	FP	VN

- VP: verdadeiros positivos
 - Número de exemplos da classe + classificados corretamente
- VN: verdadeiros negativos
 - Número de exemplos da classe - classificados corretamente
- FP: falsos positivos
 - Número de exemplos da classe - classificados incorretamente como +
- FN: falsos negativos
 - Número de exemplos da classe + classificados incorretamente como -

Revisão: métricas para classificação binária

		Classe Predita	
		+	-
Classe Verdadeira	+	VP	FN
	-	FP	VN

- Precisão

- Proporção de exemplos + classificados corretamente entre os preditos como +

$$p = \frac{VP}{VP + FP}$$

- Revocação

- Taxa de acerto na classe positiva (taxa de verdadeiros positivos)

$$r = \frac{VP}{VP + FN}$$

Revisão: métricas para classificação binária

Precisão vs revocação

		Classe Predita	
		+	-
Classe Verdadeira	+	VP	FN=?
	-	FP=0	VN

- **Precisão:** exatidão do modelo

- Ex. *Precisão* = 1.0 para uma classe C:

- Itens rotulados como C realmente pertencem a C
- Não fornece informação sobre exemplos de C que não foram corretamente classificados

$$p(f) = \frac{VP}{VP + FP}$$

Revisão: métricas para classificação binária

Precisão vs revocação

		Classe Predita	
		+	-
Classe Verdadeira	+	VP	FN=0
	-	FP=?	VN

- **Revocação:** completude do modelo
 - Ex. *Revocação* = 1.0 para uma classe C:
 - Itens da classe C foram rotulados como pertencendo a C
 - Não fornece informação sobre exemplos que foram classificados incorretamente como C

$$r(f) = \frac{VP}{VP + FN}$$

Revisão: métricas para classificação binária


		Classe Predita	
		+	-
Classe Verdadeira	+	VP	FN
	-	FP	VN

• Precisão

$$p = \frac{VP}{VP + FP}$$

• Revocação

$$r = \frac{VP}{VP + FN}$$




Revisão: métricas para classificação binária

$$p = \frac{VP}{VP + FP}$$

$$r = \frac{VP}{VP + FN}$$

<https://www.v7labs.com/blog/precision-vs-recall-guide>



		Classe Predita	
		+	-
Classe Verdadeira	+	VP=3	FN=1
	-	FP=2	VN=4

		Classe Predita	
		+	-
Classe Verdadeira	+	VP=2	FN=2
	-	FP=0	VN=6

		Classe Predita	
		+	-
Classe Verdadeira	+	VP=4	FN=0
	-	FP=4	VN=2

Precisão vs revocação

- Exemplo:

- Suponha que um programa de computador para o reconhecimento de cães em cenas de um vídeo identifica 7 cães em uma cena contendo 9 cães e alguns gatos. Se 4 das identificações estão corretas, mas 3 são, na verdade, gatos, qual a precisão e revocação do programa?

		Classe Preditada	
		+	-
Classe Verdadeira	+	VP	FN
	-	FP	VN

$$p(f) = \frac{VP}{VP + FN}$$

$$r(f) = TVP(f) = \frac{VP}{VP + FP}$$

Precisão vs revocação

- Exercício:

- Suponha que um programa de computador para o reconhecimento de cães em cenas de um vídeo identifica 7 cães em uma cena contendo 9 cães e alguns gatos. Se 4 das identificações estão corretas (VP), mas 3 são, na verdade, gatos (FP), a precisão do programa é 4/7 enquanto a sua revocação é 4/9.

		Classe Predita	
		+	-
Classe Verdadeira	+	VP=4	FN=5
	-	FP=3	VN=?

Situação descrita

- Classe +: cães
- A cena tem 9 cães reais e alguns (?) gatos.
- O programa identificou 7 cães.
 - Dessas 7 identificações:
 - 4 eram realmente cães (corretas).
 - 3 eram gatos, confundidos como cães (falsos positivos).

Portanto:

- Verdadeiros Positivos (VP) = 4
- Falsos Positivos (FP) = 3
- Falsos Negativos (FN) = $9 - 4 = 5$ (cães que estavam na cena, mas não foram detectados)
- Verdadeiros Negativos (VN) = não foi especificado o número total de gatos, então não podemos calcular o VN exato. Mas para precisão e revocação, não precisamos de VN.

Precisão vs revocação

- Exercício:

- Suponha que um programa de computador para o reconhecimento de cães em cenas de um vídeo identifica 7 cães em uma cena contendo 9 cães e alguns gatos. Se 4 das identificações estão corretas (VP), mas 3 são, na verdade, gatos (FP), a precisão do programa é 4/7 enquanto a sua revocação é 4/9.

		Classe Predita	
		+	-
Classe Verdadeira	+	VP=4	FN=5
	-	FP=3	VN=?

$$p(f) = \frac{VP}{VP + FP} = \frac{4}{4 + 3} = \boxed{\frac{4}{7}}$$

$$r(f) = TVP(f) = \frac{VP}{VP + FN} = \frac{4}{4 + 5} = \boxed{\frac{4}{9}}$$

Precisão e Revocação de Variedades

- Definições

- Precisão


- Fração de amostras geradas pelo modelo que se encontram na variedade dos dados.
 - Mede o quão realistas são as amostras geradas (**qualidade**).

- Revocação


- Fração de exemplos reais que se encontram na variedade dos dados gerados pelo modelo.
 - Mede a cobertura do modelo generativo (**diversidade**).

Precisão e Revocação de Variedades


Distribuição dos
dados **reais** (P_r)



Precisão



Revocação




T. Kynkäänniemi et al., "Improved Precision and Recall Metric for Assessing Generative Models," *Adv. Neural Inf. Process. Syst.*, vol. 32, no. NeurIPS, Apr. 2019.


Distribuição dos
dados **gerados** (P_g)

Precisão e Revocação de Variedades


Distribuição dos
dados **reais** (P_r)



Precisão



Revocação



T. Kynkäänniemi et al., "Improved Precision and Recall Metric for Assessing Generative Models," *Adv. Neural Inf. Process. Syst.*, vol. 32, no. NeurIPS, Apr. 2019.

Distribuição dos
dados **gerados** (P_g)


Amostras não
realistas

Modelo não gera amostras
desse subconjunto dos dados


Precisão e Revocação de Variedades

- Aproximação de variedades
 - Para cada ponto dos dados, cria-se uma hiperesfera de raio igual à distância ao k -ésimo vizinho mais próximo.
 - A união dessas hiperesferas $\approx$ variedade.
 - Testar se um ponto pertence à essa aproximação é simples.
 - A aproximação é geralmente computada no espaço de vetores de características de um classificador pré-treinado.

Variedade verdadeira



Variedade aproximada



T. Kynkäänniemi et al., "Improved Precision and Recall Metric for Assessing Generative Models," *Adv. Neural Inf. Process. Syst.*, vol. 32, no. NeurIPS, Apr. 2019.

Precisão e Revocação de Variedades

- Aproximação de variedades
 - Abordagem não-paramétrica usando espaços de características (*features*).
 - Amostras reais e geradas são incorporadas em um espaço de características:

$$\Phi_r = \left\{ \phi_r^{(i)} \right\}_{i=1}^N, \quad (\text{dados reais})$$

$$\Phi_g = \left\{ \phi_g^{(i)} \right\}_{i=1}^N, \quad (\text{dados gerados})$$

- Utiliza-se uma rede neural pré-treinada para calcular os vetores de características ϕ .

Precisão e Revocação de Variedades

- Aproximação de variedades

- Para cada ponto ϕ no espaço de características, define-se uma hiperesfera com raio dado por

$$r_k(\phi) = \|\phi - NN_k(\phi, \Phi)\|_2$$

- $NN_k(\phi, \Phi)$: função que retorna o k-ésimo vizinho mais próximo de ϕ em Φ .
- Podemos então definir a função indicadora para verificar se um ponto está dentro da hiperesfera:

$$f_k(\phi, \Phi) = \begin{cases} 1, & \text{se } \exists \phi' \in \Phi : \|\phi - \phi'\|_2 \leq r_k(\phi') \\ 0, & \text{caso contrário} \end{cases}$$

Ou seja, ϕ está dentro da hiperesfera de algum $\phi' \in \Phi$, e portanto se encontra na variedade.

Precisão e Revocação de Variedades

- Aproximação de variedades
 - Precisão


$$p(\Phi_r, \Phi_g) = \frac{1}{|\Phi_g|} \sum_{\phi_g \in \Phi_g} f_k(\phi_g, \Phi_r), \quad p \in [0,1]$$

- Revocação

$$r(\Phi_r, \Phi_g) = \frac{1}{|\Phi_r|} \sum_{\phi_r \in \Phi_r} f_k(\phi_r, \Phi_g), \quad r \in [0,1]$$

- Hiperparâmetro k regula tolerância: $k \uparrow \Rightarrow$ métricas mais altas.


Precisão e Revocação de Variedades



Approximate synthetic
manifold





Approximate real
manifold



Precision
computation

Precisão e Revocação de Variedades

- Precisão e revocação podem ser utilizadas para construir uma curva de compromisso (*trade-off*) permitindo a comparação entre modelos diferentes e/ou hiper-parametrizações.



Alta qualidade & alta diversidade.

Configuration	FID
A) StyleGAN	4.43
B) No mb. std.	8.58
C) B + low γ	10.34
D) No growing	6.14
E) Rand. trans.	4.27
F) No inst. norm.	4.16

Precisão e Revocação de Variedades

- Relação com FID
 - FID mistura distorções de qualidade/diversidade
 - Difícil saber a causa de um mau desempenho.
 - Precisão e revocação oferecem diagnóstico detalhado:
 - Baixa precisão: amostras parecem irreais.
 - Baixa revocação: modelo não cobre toda a distribuição (ex.: *mode collapse* nas GANs).

Testes estatísticos (testes de duas amostras)

- Pergunta central: os dois conjuntos de amostras são oriundos da **mesma distribuição**?
 - Hipótese nula (H_0): os dois conjuntos de amostras provêm da mesma distribuição.
 - Procedimento:
 1. Calcular uma estatística a partir das amostras
 2. Comparar a estatística ao limiar e decidir se rejeita H_0
- Realizados utilizando **vetores de características** ao invés dos dados brutos de alta dimensionalidade.
- **Vantagem:** controle explícito do erro Tipo I (probabilidade de rejeitar erroneamente H_0).
- **Desvantagem:**
 - Podem ter custo computacional elevado tornando-se impróprios para monitorar treinamento.
 - Adequados para comparar modelos já treinados.

Desafios no uso de classificadores pré-treinados

- Métricas que dependem de vetores de características de classificador pré-treinado:
 - IS
 - FID
 - Precisão e revocação de variedades (calculados no espaço de características)
 - Testes estatísticos (calculados no espaço de características)
- Classificador e modelo generativo treinados em conjuntos de dados distintos (ausência de classificador adequado)
- Classificador e modelo generativo treinados no mesmo conjunto de dados

Desafios no uso de classificadores pré-treinados

- Métricas que dependem de vetores de características de classificador pré-treinado:
 - IS
 - FID
 - Precisão e revocação de variedades (calculados no espaço de características)
 - Testes estatísticos (calculados no espaço de características)
- Classificador e modelo generativo treinados em conjuntos de dados distintos (ausência de classificador adequado)
 - Problemas de generalização das redes neurais: vetores de características extraídos do classificador treinado a partir de um conjunto de dados podem ser pouco confiáveis para avaliar as amostras produzidas por um modelo generativo treinado em outro conjunto de dados.
- Classificador e modelo generativo treinados no mesmo conjunto de dados
 - Um gerador imperfeito produz amostras fora da distribuição da qual o classificador foi treinado (isto é, não vistas durante seu treinamento) e a avaliação do modelo generativo baseia-se justamente nos vetores de características produzidos pelo classificador.

Outros métodos de avaliação

- Treinar modelos de aprendizado de máquina com amostras sintéticas
 - Usar dados sintéticos no treinamento de modelos de aprendizado de máquina e medir o ganho em tarefas *downstream* (aprendizado supervisionado, aprendizado semi-supervisionado, aprendizado por reforço baseado em modelo).
 - Avalia a utilidade prática das amostras sintéticas observando a melhoria na performance do modelo de aprendizado de máquina, por exemplo:
 - Acurácia de classificadores em conjuntos de teste
 - Performance de agentes em aprendizado por reforço
- Avaliação humana
 - Avaliadores comparam amostras geradas e reais.
 - Adequado quando a percepção humana é critério principal ou faltam métricas automáticas confiáveis.
 - **Desvantagens:** processo pode ser caro e difícil de padronizar e automatizar.

Detecção de sobreajuste (*overfitting*)

- Inspeção visual com k-NN
 1. Gerar amostras do modelo.
 2. Para cada amostra, buscar os k vizinhos mais próximos (vetor de características de um classificador pré-treinado) no conjunto de dados.
 3. Se a amostra diferir claramente dos vizinhos $\Rightarrow$ sinal de que não foi memorizada.
- Simples, mas depende de avaliação humana.



- Simon J. D. Prince. Understanding Deep Learning, The MIT Press, 2023. [capítulo 14]
 - disponível em: <https://udlbook.github.io/udlbook/>
- Kevin P. Murphy. Probabilistic Machine Learning: Advanced Topics, MIT Press, 2023. [capítulo 20]
 - disponível em: <https://probml.github.io/pml-book/book2.html>

Slides construídos com base nos livros supracitados, os quais estão disponibilizados publicamente pelos seus autores.

Referências complementares

- T. Kynkäänniemi et al., “Improved Precision and Recall Metric for Assessing Generative Models,” *Adv. Neural Inf. Process. Syst.*, vol. 32, no. NeurIPS, Apr. 2019.