# *Autoencoders* Variacionais

# Modelos de variáveis latentes I

- **Qual é o nosso objetivo?**
  - Modelar a distribuição dos dados desconhecida $p^*(\boldsymbol{x})$.
- **Como vamos alcançar o nosso objetivo?**
  - Introduzimos uma variável latente (não-observável) $\boldsymbol{z}$.
  - Estabelecemos a distribuição conjunta dos dados $\boldsymbol{x}$ e das variáveis latentes $\boldsymbol{z}$:

$$p(\boldsymbol{x}, \boldsymbol{z}) = p(\boldsymbol{x}|\boldsymbol{z})p(\boldsymbol{z}) \quad \text{(regra das probabilidades condicionais)}$$

  - Fazemos uma modelagem paramétrica ($\phi$) da forma:

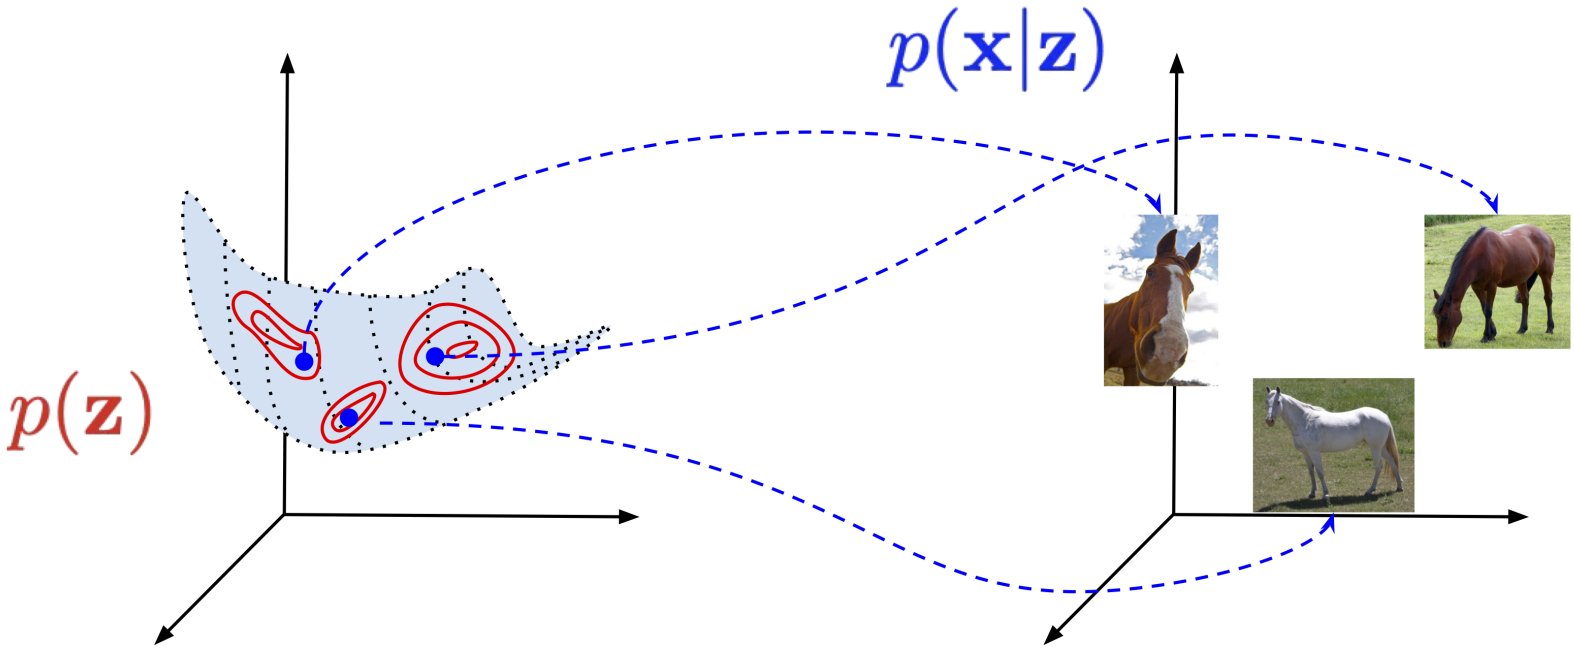
$$p^*(\boldsymbol{x}) \approx p_\phi(\boldsymbol{x}) = \int p_\phi(\boldsymbol{x}, \boldsymbol{z})\, d\boldsymbol{z} \quad \text{(marginalização)}$$

$$= \boxed{\int p_\phi(\boldsymbol{x}|\boldsymbol{z})p(\boldsymbol{z})\, d\boldsymbol{z}}$$

# Modelos de variáveis latentes II

– Queremos aprender o modelo condicional $p_\phi(\boldsymbol{x}|\boldsymbol{z})$ para gerar novas amostras:

$$\boldsymbol{z}_{novo} \sim p(\boldsymbol{z}) \longrightarrow \boldsymbol{x}_{novo} \sim p_\phi(\boldsymbol{x}|\boldsymbol{z}_{novo})$$




https://jmtomczak.github.io/blog/4/4_VAE.html

# Modelos de variáveis latentes III

- Nomenclatura
  - $p(\boldsymbol{x}|\boldsymbol{z})$: verossimilhança dos dados dado a variável latente $\boldsymbol{z}$
  - $p(\boldsymbol{z})$: distribuição a priori

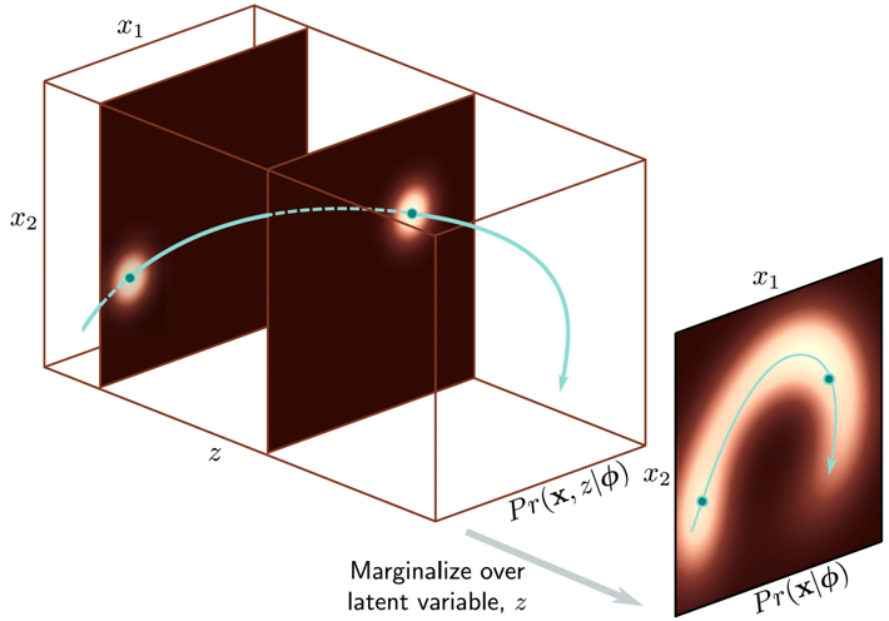
# Modelos de variáveis latentes IV

– Essa abordagem indireta permite definir distribuições $p_\phi(\boldsymbol{x})$ complexas a partir de distribuições $p_\phi(\boldsymbol{x}|\boldsymbol{z})$ e $p(\boldsymbol{z})$ relativamente simples.

$$p(\boldsymbol{z}) = \mathcal{N}(\boldsymbol{z} \mid \mathbf{0}, \boldsymbol{I})$$

$$p(\boldsymbol{x}|\boldsymbol{z}, \phi) = \mathcal{N}(\boldsymbol{x} \mid f(\boldsymbol{z}, \phi), \sigma^2 \boldsymbol{I})$$

$$\begin{aligned} p(\boldsymbol{x}|\boldsymbol{\phi}) &= \int p(\boldsymbol{x}, \boldsymbol{z}|\phi)\, d\boldsymbol{z} \\ &= \int p(\boldsymbol{x}|\boldsymbol{z}, \phi) p(\boldsymbol{z})\, d\boldsymbol{z} \\ &= \int \mathcal{N}(\boldsymbol{x} \mid f(\boldsymbol{z}, \phi), \sigma^2 \boldsymbol{I}) \mathcal{N}(\boldsymbol{z}|\mathbf{0}, \boldsymbol{I})\, d\boldsymbol{z} \end{aligned}$$




- $f(\boldsymbol{z}, \phi)$: função não-linear das variáveis latentes $\boldsymbol{z}$ (rede neural profunda com parâmetros $\phi$).

# Modelos de variáveis latentes V

- **Mas qual é o problema? E onde está o *encoder* (codificador)?**
  - Para treinar o nosso modelo devemos maximizar o logaritmo da verossimilhança dado um conjunto de treinamento $\mathcal{D} = \{\boldsymbol{x}_n\}_{n=1}^N$:

$$\hat{\phi} = \arg\max_{\phi} \sum_{\boldsymbol{x} \in \mathcal{D}} \ln p_\phi(\boldsymbol{x})$$

  - Porém a integral

$$p_\phi(\boldsymbol{x}) = \int p_\phi(\boldsymbol{x}|\boldsymbol{z}) p(\boldsymbol{z})\, d\boldsymbol{z}$$

    é **intratável** (não tem solução analítica)!

# Limite inferior da evidência I

- **Qual a solução?**
  - Limite inferior da evidência (ELBO, do inglês *evidence lower bound*): define um limite inferior para o logaritmo da verossimilhança ($\ln p_\phi(\boldsymbol{x})$).
  - Introduzimos uma distribuição de probabilidade arbitrária $q_\theta(\boldsymbol{z})$ com parâmetros $\theta$ sobre as variáveis latentes .

## Terminologia

A terminologia (ELBO) se deve ao contexto da fórmula de Bayes:

$$\underbrace{p(\boldsymbol{z}|\boldsymbol{x})}_{\text{probabilidade a posteriori}} = \frac{\overbrace{p(\boldsymbol{x}|\boldsymbol{z})}^{\text{verossimilhança}} \cdot \overbrace{p(\boldsymbol{z})}^{\text{probabilidade a priori}}}{\underbrace{p(\boldsymbol{x})}_{\text{evidência}}}$$

# Limite inferior da evidência II

## Derivação do ELBO:

$$\ln p_\phi(\boldsymbol{x}) = \mathbb{E}_{q_\theta(\boldsymbol{z})}\left[\ln p_\phi(\boldsymbol{x})\right]$$

$\ln p_\phi(\boldsymbol{x})$ independe de $q_\theta(\boldsymbol{z})$

$$= \mathbb{E}_{q_\theta(\boldsymbol{z})}\left[\ln \frac{p_\phi(\boldsymbol{x},\boldsymbol{z})}{p_\phi(\boldsymbol{z}|\boldsymbol{x})}\right]$$

$$p(\boldsymbol{x}) = \frac{p(\boldsymbol{x},\boldsymbol{z})}{p(\boldsymbol{z}|\boldsymbol{x})}$$

$$= \mathbb{E}_{q_\theta(\boldsymbol{z})}\left[\ln \frac{p_\phi(\boldsymbol{x},\boldsymbol{z})}{p_\phi(\boldsymbol{z}|\boldsymbol{x})}\frac{q_\theta(\boldsymbol{z})}{q_\theta(\boldsymbol{z})}\right]$$

$$\frac{q_\theta(\boldsymbol{z})}{q_\theta(\boldsymbol{z})} = 1$$

$$= \mathbb{E}_{q_\theta(\boldsymbol{z})}\left[\ln \frac{p_\phi(\boldsymbol{x},\boldsymbol{z})}{q_\theta(\boldsymbol{z})}\frac{q_\theta(\boldsymbol{z})}{p_\phi(\boldsymbol{z}|\boldsymbol{x})}\right]$$

$$= \mathbb{E}_{q_\theta(\boldsymbol{z})}\left[\ln \frac{p_\phi(\boldsymbol{x},\boldsymbol{z})}{q_\theta(\boldsymbol{z})} - \ln \frac{p_\phi(\boldsymbol{z}|\boldsymbol{x})}{q_\theta(\boldsymbol{z})}\right]$$

$$= \underbrace{\mathbb{E}_{q_\theta(\boldsymbol{z})}\left[\ln \frac{p_\phi(\boldsymbol{x},\boldsymbol{z})}{q_\theta(\boldsymbol{z})}\right]}_{\text{ELBO}} \underbrace{-\mathbb{E}_{q_\theta(\boldsymbol{z})}\left[\ln \frac{p_\phi(\boldsymbol{z}|\boldsymbol{x})}{q_\theta(\boldsymbol{z})}\right]}_{\text{divergência de Kullback-Leibler}}$$

$$= \text{ELBO}(\theta,\phi) + \underbrace{\mathbb{KL}(q_\theta(\boldsymbol{z}) \parallel p_\phi(\boldsymbol{z}|\boldsymbol{x}))}_{\geq 0}$$

$\ln p_\phi(\boldsymbol{x}) \geq \text{ELBO}(\theta,\phi)$

# Limite inferior da evidência III

## Definição

A divergência de Kullback-Leibler entre duas distribuições $q(\boldsymbol{x})$ e $p(\boldsymbol{x})$ é definida como:

$$\begin{aligned}\mathbb{KL}(q(\boldsymbol{x}) \parallel p(\boldsymbol{x})) &= \mathbb{E}_{q(\boldsymbol{x})}\left[\ln \frac{q(\boldsymbol{x})}{p(\boldsymbol{x})}\right] \\ &= \int q(\boldsymbol{x}) \ln \frac{q(\boldsymbol{x})}{p(\boldsymbol{x})}\, d\boldsymbol{x}.\end{aligned}$$

# Limite inferior da evidência IV

## Propriedades

1. **Não-negatividade:**
$$\mathbb{KL}(q \parallel p) \geq 0$$
2. **Assimetria:**
$$\mathbb{KL}(q \parallel p) \neq \mathbb{KL}(p \parallel q)$$
3. **Zero se e somente se as distribuições forem iguais:**
$$\mathbb{KL}(q \parallel p) = 0 \Leftrightarrow q(\cdot) = p(\cdot)$$

# Limite inferior da evidência V

- Para o ELBO ser justo ($\ln p_\phi(\boldsymbol{x}) = \text{ELBO}(\theta, \phi)$) devemos ter $q_\theta(\boldsymbol{z}) = p_\phi(\boldsymbol{z}|\boldsymbol{x})$ (pois teremos uma divergencia de $\mathbb{KL}$ nula).
- A distribuição a posteriori $p_\phi(\boldsymbol{z}|\boldsymbol{x})$ é dada pela regra de Bayes:

$$p_\phi(\boldsymbol{z}|\boldsymbol{x}) = \frac{p_\phi(\boldsymbol{x}|\boldsymbol{z})p(\boldsymbol{z})}{p_\phi(\boldsymbol{x})}$$

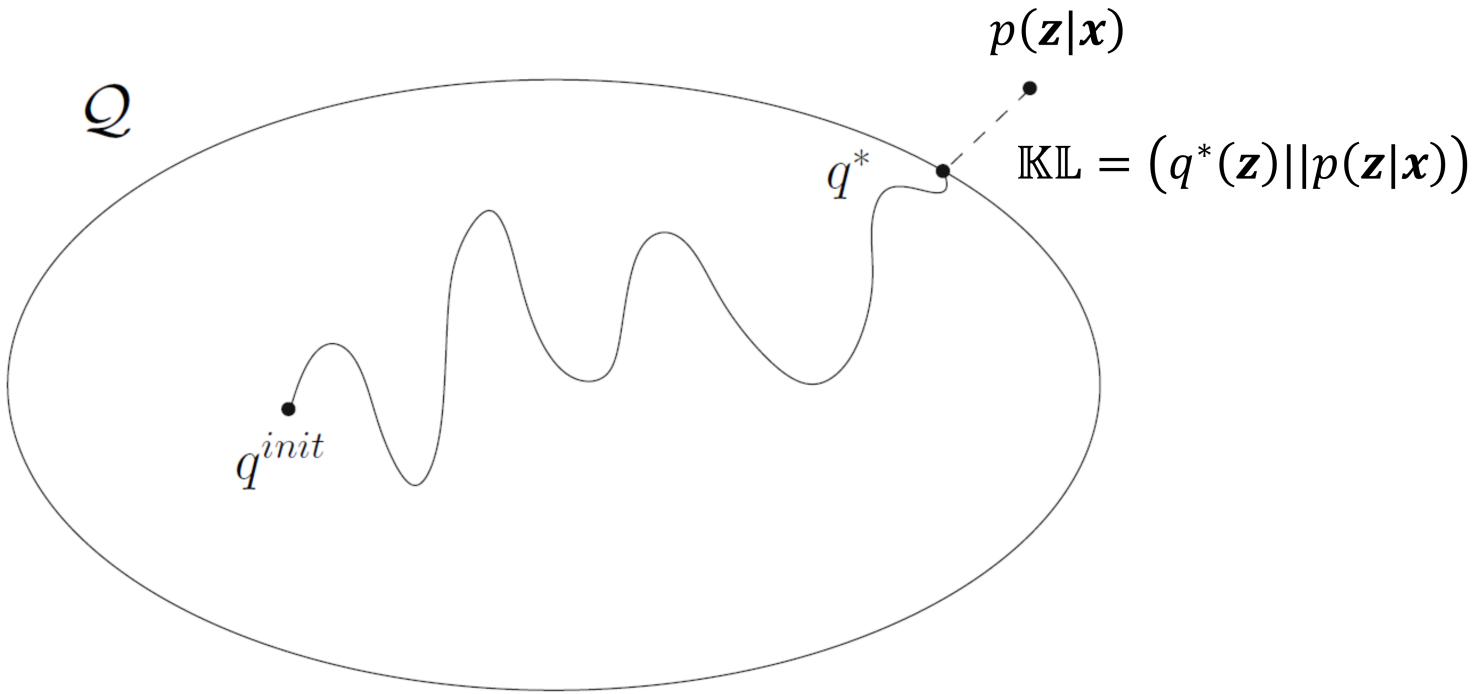
- **Problema**: A equação acima é intratável (lembre-se que a evidência $p_\phi(\boldsymbol{x})$ do modelo não pode ser calculada analiticamente!)
- **Solução**: aproximação variacional.

# Inferência variacional I

- Inferência variacional:
  - Conjunto de técnicas para aproximar distribuições de probabilidade complicadas (ex.: a condicional exata $p(\boldsymbol{z} \mid \boldsymbol{x})$) por uma função de densidade $q^*(\boldsymbol{z}) \in \mathcal{Q}$, onde $\mathcal{Q}$ é uma família predefinida de densidades aproximadas sobre as variáveis latentes.
  - Problema de otimização: minimizar a seguinte divergência de Kullback-Leibler:

$$q^*(\boldsymbol{z}) = \arg\min_{q \in \mathcal{Q}} \mathbb{KL}\left(q(\boldsymbol{z}) \parallel p(\boldsymbol{z} \mid \boldsymbol{x})\right)$$

# Inferência variacional II




---

Adaptado de L. P. Cinelli *et al.*, *Variational Methods for Machine Learning with Applications to Deep Networks*, Springer Cham, 2021.

# Inferência variacional III

- A densidade aproximada $q$ pode ou não depender dos dados.
- Queremos gerar amostras apenas de valores de $\boldsymbol{z}$ que provavelmente produziram $\boldsymbol{x}$, em vez de amostrar todo o espaço latente sob a probabilidade a priori $p(\boldsymbol{z})$.
- Portanto, escolhemos uma forma paramétrica simples para a densidade aproximada $q_\theta(\boldsymbol{z})$ e que dependa de $\boldsymbol{x}$ tal qual $p_\phi(\boldsymbol{z}|\boldsymbol{x})$ (já que esta última é a escolha ótima para $q_\theta(\boldsymbol{z})$). Ou seja, projetamos $q$ como condicionada às observações e parametrizada por $\theta$.

# Inferência variacional IV

- Por exemplo:

$$q_\theta(\boldsymbol{z}|\boldsymbol{x}) = \mathcal{N}(\boldsymbol{z}|\boldsymbol{\mu}(\boldsymbol{x},\theta), \boldsymbol{\Sigma}(\boldsymbol{x},\theta))$$

$$g(\boldsymbol{x},\theta) = \begin{bmatrix} \boldsymbol{\mu}(\boldsymbol{x},\theta) \\ \boldsymbol{\Sigma}(\boldsymbol{x},\theta) \end{bmatrix}$$

- Aonde $g(\boldsymbol{x},\theta)$ é uma segunda rede neural profunda (codificador (*encoder*)).

# Inferência variacional V

– Derivação alternativa do ELBO:

$$\mathbb{KL}(q_\theta(\boldsymbol{z}|\boldsymbol{x}) \,\|\, p_\phi(\boldsymbol{z}|\boldsymbol{x})) = \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln \frac{q_\theta(\boldsymbol{z}|\boldsymbol{x})}{p_\phi(\boldsymbol{z}|\boldsymbol{x})}\right] \quad \text{Definição de } \mathbb{KL}$$

$$= \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln \frac{q_\theta(\boldsymbol{z}|\boldsymbol{x})\, p_\phi(\boldsymbol{x})}{p_\phi(\boldsymbol{x}|\boldsymbol{z})\, p(\boldsymbol{z})}\right] \quad \text{Bayes: } p_\phi(\boldsymbol{z}|\boldsymbol{x}) = \frac{p_\phi(\boldsymbol{x}|\boldsymbol{z})\, p(\boldsymbol{z})}{p_\phi(\boldsymbol{x})}$$

$$= \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln \frac{q_\theta(\boldsymbol{z}|\boldsymbol{x})}{p_\phi(\boldsymbol{x}|\boldsymbol{z})\, p(\boldsymbol{z})}\right] + \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}[\ln p_\phi(\boldsymbol{x})] \quad \text{Linearidade da } \mathbb{E}[\cdot]$$

$$= -\,\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln \frac{p_\phi(\boldsymbol{x}|\boldsymbol{z})\, p(\boldsymbol{z})}{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\right] + \ln p_\phi(\boldsymbol{x}) \quad \ln p_\phi(\boldsymbol{x}) \text{ independe de } q_\theta(\boldsymbol{z}|\boldsymbol{x})$$

$$= -\underbrace{\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln \frac{p_\phi(\boldsymbol{x},\boldsymbol{z})}{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\right]}_{\text{ELBO}} + \ln p_\phi(\boldsymbol{x}) \quad p_\phi(\boldsymbol{x},\boldsymbol{z}) = p_\phi(\boldsymbol{x}|\boldsymbol{z})\, p(\boldsymbol{z})$$

$$= -\,\text{ELBO}(\theta,\phi) + \ln p_\phi(\boldsymbol{x}) \quad \text{Definição de ELBO}$$

$$\Rightarrow \ln p_\phi(\boldsymbol{x}) = \text{ELBO}(\theta,\phi) + \mathbb{KL}(q_\theta(\boldsymbol{z}|\boldsymbol{x}) \,\|\, p_\phi(\boldsymbol{z}|\boldsymbol{x}))$$

$$\ln p_\phi(\boldsymbol{x}) \geq \text{ELBO}(\theta,\phi)$$

# Inferência variacional VI

- ELBO:

$$\boxed{\ln p_\phi(\boldsymbol{x}) = \text{ELBO}(\theta, \phi) + \mathbb{KL}\left(q_\theta(\boldsymbol{z}|\boldsymbol{x}) \parallel p_\phi(\boldsymbol{z}|\boldsymbol{x})\right)}$$

- Componentes do ELBO:

$$\begin{aligned}
\text{ELBO}(\theta, \phi) &= \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln \frac{p_\phi(\boldsymbol{x}, \boldsymbol{z})}{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\right] = \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln \frac{p_\phi(\boldsymbol{x}|\boldsymbol{z})p(\boldsymbol{z})}{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\right] \\
&= \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln p_\phi(\boldsymbol{x}|\boldsymbol{z})\right] + \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln \frac{p(\boldsymbol{z})}{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\right] \\
&= \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln p_\phi(\boldsymbol{x}|\boldsymbol{z})\right] - \mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln \frac{q_\theta(\boldsymbol{z}|\boldsymbol{x})}{p(\boldsymbol{z})}\right] \\
&= \underbrace{\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln p_\phi(\boldsymbol{x}|\boldsymbol{z})\right]}_{\substack{\text{decodificador} \\ \text{(decoder)} \\ \text{termo de reconstrução}}} - \underbrace{\mathbb{KL}\left(q_\theta(\boldsymbol{z}|\boldsymbol{x}) \parallel p(\boldsymbol{z})\right)}_{\substack{\text{codificador} \\ \text{(encoder)} \\ \text{termo de regularização}}}
\end{aligned}$$

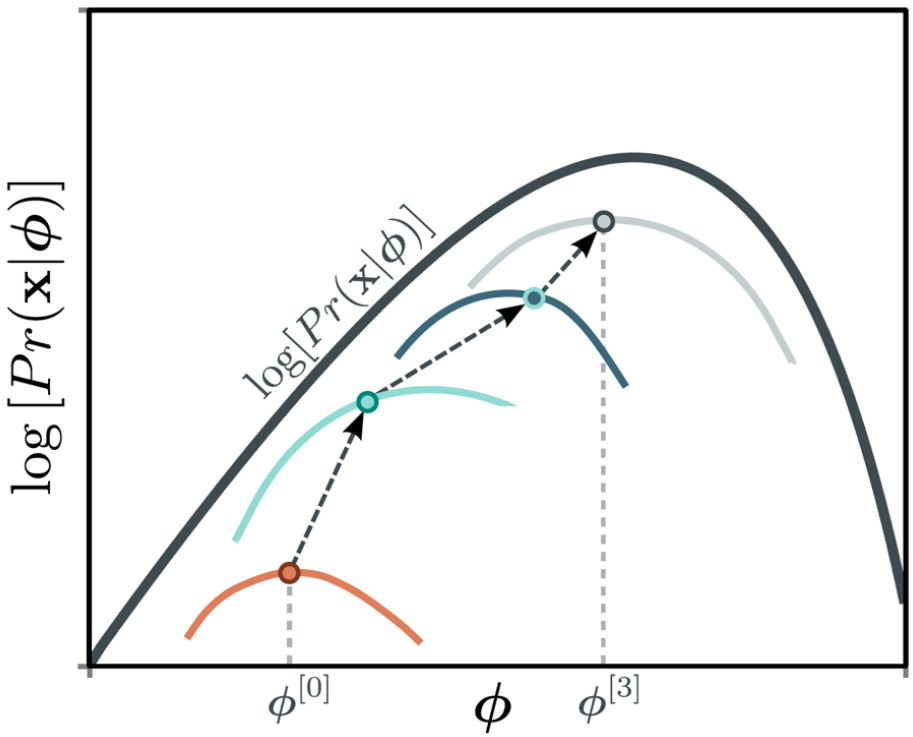
# Inferência variacional VII

| Distribuição | Descrição | Tratável? |
|---|---|---|
| $p_\phi(\boldsymbol{x})$ | Distribuição dos dados | ✗ |
| $p_\phi(\boldsymbol{z}\|\boldsymbol{x})$ | Distribuição a posteriori | ✗ |
| $p_\phi(\boldsymbol{x}\|\boldsymbol{z})$ | Distribuição condicional dos dados dado $\boldsymbol{z}$ | ✓ |
| $p(\boldsymbol{z})$ | Distribuição a priori | ✓ |
| $q_\theta(\boldsymbol{z}\|\boldsymbol{x})$ | Distribuição variacional | ✓ |

Tabela: Distribuições aproximadas no *autoencoder* variacional

# Inferência variacional VIII

Aproximação variacional



# Inferência variacional IX

- Termo de reconstrução
  - O termo $\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln p_\phi(\boldsymbol{x}|\boldsymbol{z})\right]$ pode ser aproximado utilizando a estimativa de Monte Carlo:

$$\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}[\ln p_\phi(\boldsymbol{x}|\boldsymbol{z})] = \int \ln p_\phi(\boldsymbol{x}|\boldsymbol{z}) \cdot q_\theta(\boldsymbol{z}|\boldsymbol{x}) d\boldsymbol{z}$$

$$\approx \frac{1}{L}\sum_{l=1}^{L} \ln p_\phi(\boldsymbol{x}|\boldsymbol{z}_l^*), \quad \boldsymbol{z}_l^* \sim q_\theta(\boldsymbol{z}|\boldsymbol{x})$$

Onde escolhas comuns são:

$$p_\phi(\boldsymbol{x}|\boldsymbol{z}) = \mathcal{N}(\boldsymbol{x} \mid \boldsymbol{\mu}_\phi(\boldsymbol{z}), \sigma^2_{\text{dec}}\boldsymbol{I}) \quad , \quad \sigma_{\text{dec}} \text{ é um hiperparâmetro}$$

$$q_\theta(\boldsymbol{z}|\boldsymbol{x}) = \mathcal{N}(\boldsymbol{z} \mid \boldsymbol{\mu}_\theta(\boldsymbol{x}), diag(\sigma^2_\theta(\boldsymbol{x})))$$

# Inferência variacional X

- Fazendo $L = 1$:

$$\mathbb{E}_{q(\boldsymbol{z}|\boldsymbol{x},\theta)}\left[\ln p_\phi(\boldsymbol{x}|\boldsymbol{z})\right] \approx \ln p_\phi(\boldsymbol{x}|\boldsymbol{z}^*), \quad \boldsymbol{z}^* \sim q_\theta(\boldsymbol{z}|\boldsymbol{x})$$

Onde,

$$\begin{aligned}
\ln p_{\boldsymbol{\phi}}(\boldsymbol{x}|\boldsymbol{z}) &= \ln \mathcal{N}(\boldsymbol{x} \,|\, \boldsymbol{\mu}_{\boldsymbol{\phi}}(\boldsymbol{z}), \sigma^2_{\text{dec}} \boldsymbol{I}) \\
&= \ln \frac{1}{\sqrt{(2\pi\sigma^2_{\text{dec}})^d}} \exp\left\{ -\frac{\|\boldsymbol{x} - \boldsymbol{\mu}_{\boldsymbol{\phi}}(\boldsymbol{z})\|^2}{2\sigma^2_{\text{dec}}} \right\} \\
&= -\frac{1}{2\sigma^2_{\text{dec}}} \|\boldsymbol{x} - f_{\boldsymbol{\phi}}(\boldsymbol{z})\|^2 \quad - \quad \underbrace{\ln \sqrt{(2\pi\sigma^2_{\text{dec}})^d}}_{\text{independe de } \boldsymbol{\phi}} \\
&= -\frac{1}{2\sigma^2_{\text{dec}}} \|\boldsymbol{x} - \boldsymbol{\mu}_{\boldsymbol{\phi}}(\boldsymbol{z})\|^2 \quad + \quad \textit{constante}
\end{aligned}$$

# Inferência variacional XI

- Termo de regularização
  - O termo $\mathbb{KL}\left(q_\theta(\boldsymbol{z}|\boldsymbol{x}) \parallel p(\boldsymbol{z})\right)$ pode ser calculado analiticamente.

## Divergência de Kullback-Leibler entre duas distribuições Gaussianas

$$\mathbb{KL}(q \parallel p) = \frac{1}{2}\left[\mathrm{tr}(\Sigma_p^{-1}\Sigma_q) + (\mu_p - \mu_q)^\top \Sigma_p^{-1}(\mu_p - \mu_q) - d + \ln\left(\frac{\det(\Sigma_p)}{\det(\Sigma_q)}\right)\right]$$

- $q = \mathcal{N}(\boldsymbol{\mu}_q, \boldsymbol{\Sigma}_q)$.
- $p = \mathcal{N}(\boldsymbol{\mu}_p, \boldsymbol{\Sigma}_p)$.
- $d$: dimensionalidade das distribuições.
- $\mathrm{tr}(\cdot)$: traço de uma matriz.
- $\det(\cdot)$: determinante de uma matriz.

# Inferência variacional XII

No nosso caso:

$$q_\theta(\boldsymbol{z}|\boldsymbol{x}) = \mathcal{N}(\boldsymbol{z}|\boldsymbol{\mu_\theta}(\boldsymbol{x}), \boldsymbol{\Sigma_\theta}(\boldsymbol{x}))$$

$$p(\boldsymbol{z}) = \mathcal{N}(\boldsymbol{z}|\boldsymbol{0}, \boldsymbol{I})$$

Então,

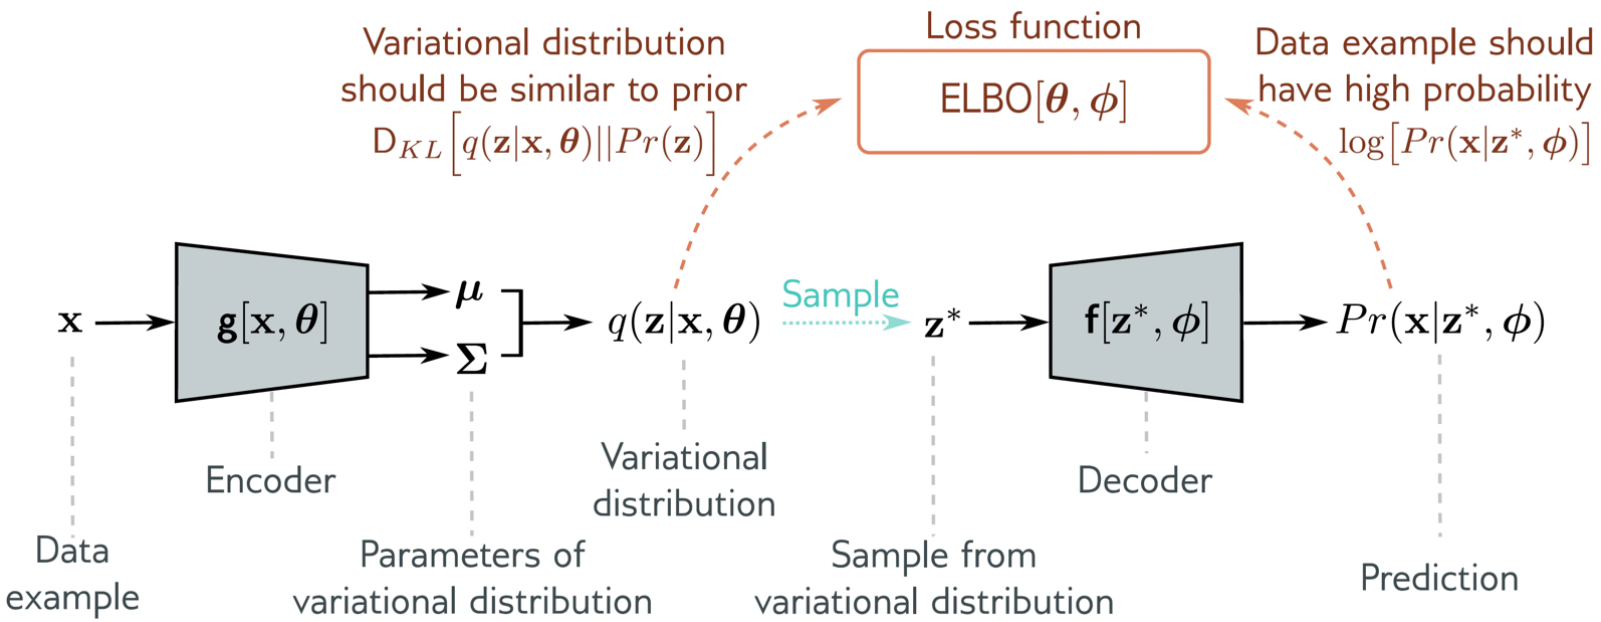
$$\mathbb{KL}\left(q_\theta(\boldsymbol{z}|\boldsymbol{x}) \parallel p(\boldsymbol{z})\right) = \frac{1}{2}\left[\mathrm{tr}(\boldsymbol{\Sigma}) + \boldsymbol{\mu}^\top\boldsymbol{\mu} - d_z - \ln\det(\boldsymbol{\Sigma})\right]$$

- $d_z$: dimensionalidade do espaço latente.

# Inferência variacional XIII

Rede neural do autoencoder variacional (VAE - do inglês *variational autoencoder*) para calcular o ELBO:

$$\text{ELBO}(\theta, \phi) \approx \ln p_\phi(\boldsymbol{x}|\boldsymbol{z}^*) - \mathbb{KL}\left(q_\theta(\boldsymbol{z}|\boldsymbol{x}) \parallel p(\boldsymbol{z})\right)$$

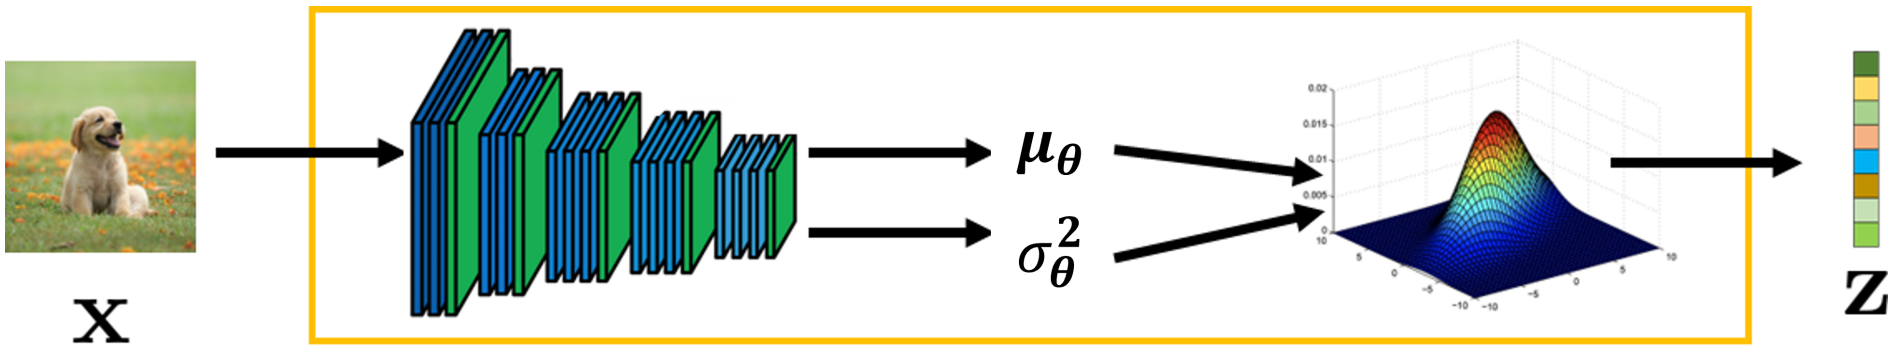


# Recapitulando I

Encoder:

$$g(\boldsymbol{x}, \boldsymbol{\theta}) = \begin{bmatrix} \boldsymbol{\mu_\theta}(\boldsymbol{x}) \\ \sigma^2_{\boldsymbol{\theta}}(\boldsymbol{x}) \end{bmatrix}$$

$$q_{\boldsymbol{\theta}}(\boldsymbol{z}|\boldsymbol{x}) = \mathcal{N}(\boldsymbol{z}|\boldsymbol{\mu_\theta}(\boldsymbol{x}), diag(\sigma^2_{\boldsymbol{\theta}}(\boldsymbol{x})))$$




---

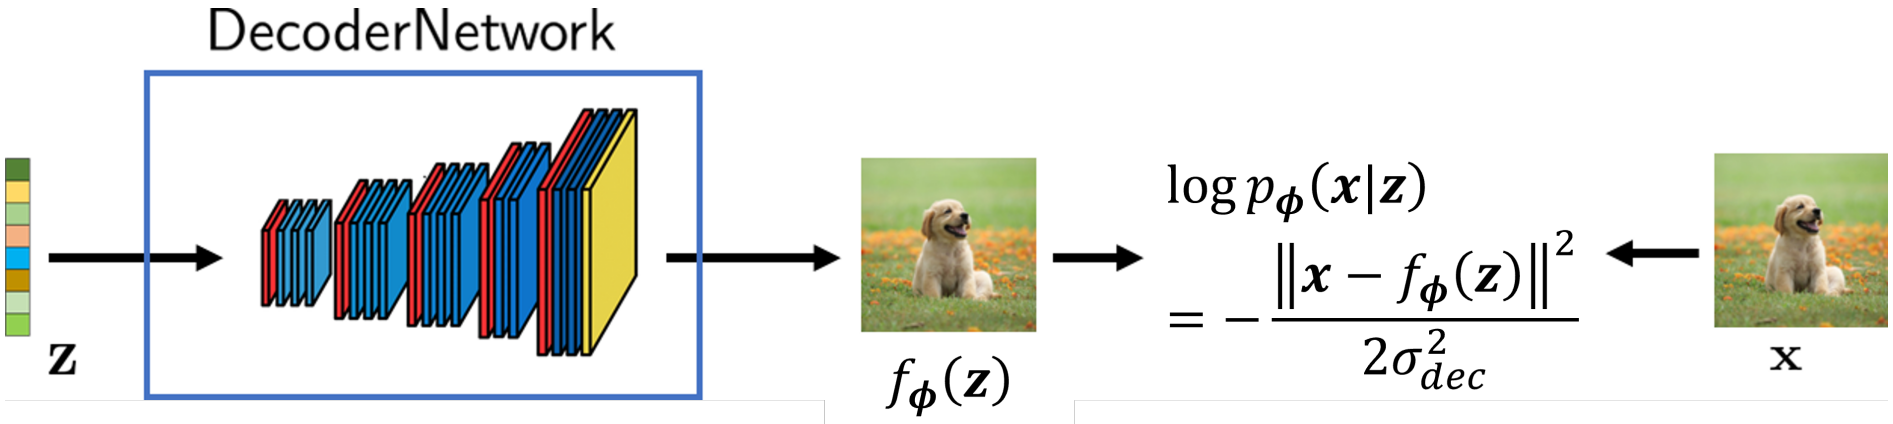
Adaptado de S. H. Chan, *Tutorial on Diffusion Models for Imaging and Vision*, arXiv:2403.18103, 2024.

# Recapitulando II

Decoder:

$$f_\phi(\boldsymbol{z}) = \begin{bmatrix} \boldsymbol{\mu}_\phi(\boldsymbol{z}) \\ \cancel{\sigma^2_\phi(\boldsymbol{z})} \end{bmatrix}$$

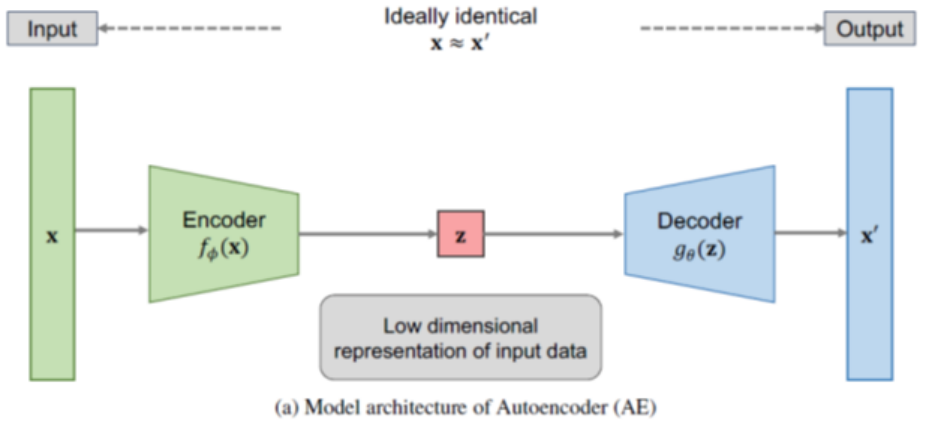
$$p_\phi(\boldsymbol{x}|\boldsymbol{z}) = \mathcal{N}(\boldsymbol{x}|\boldsymbol{\mu}_\phi(\boldsymbol{z}), \sigma^2_{\text{dec}}\boldsymbol{I}), \qquad \text{para algum hiper-parâmetro } \sigma_{\text{dec}}$$



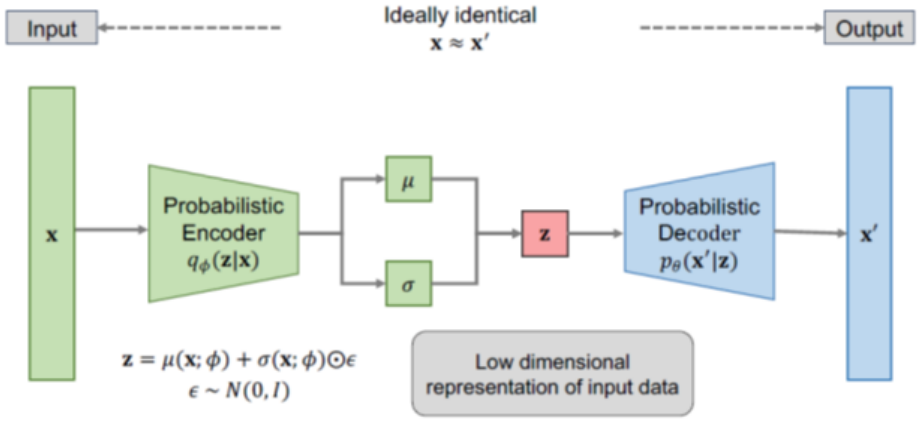

---

Adaptado de S. H. Chan, *Tutorial on Diffusion Models for Imaging and Vision*, arXiv:2403.18103, 2024.

# AE (determinístico) versus VAE (probabilístico)




(a) Model architecture of Autoencoder (AE)




(b) Model architecture of Variational Autoencoder (VAE)

---

S. Choi *et al.*, *A Gentle Introduction and Tutorial on Deep Generative Models in Transportation Research, Transportation Research Part C: Emerging Technologies*, vol. 176, 2025.

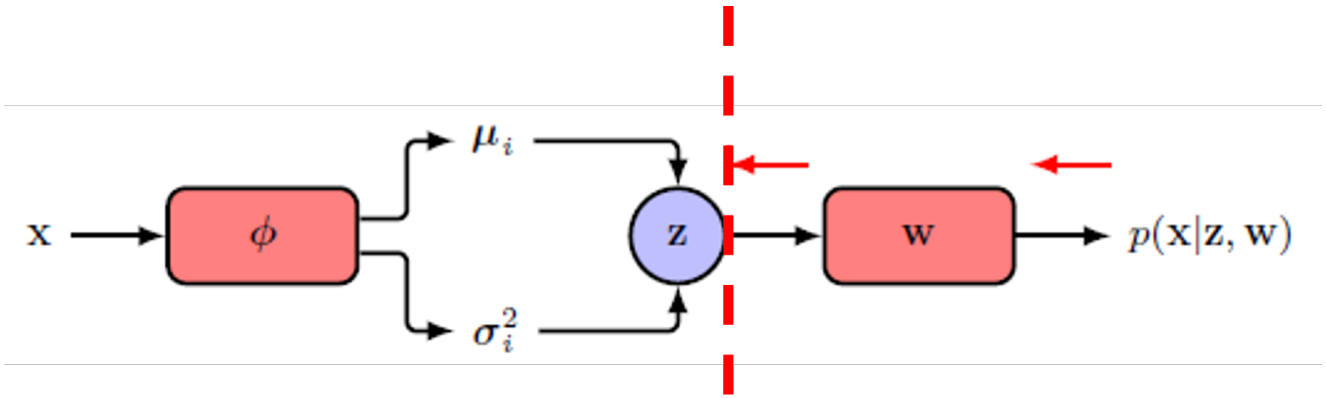
# Truque de Reparametrização I

- Objetivo de otimização do VAE: queremos maximizar o ELBO dado um conjunto de treinamento $\mathcal{D} = \{\boldsymbol{x}_i\}_{i=1}^N$:

$$(\hat{\boldsymbol{\theta}}, \hat{\boldsymbol{\phi}}) = \arg\max_{\boldsymbol{\theta},\boldsymbol{\phi}} \sum_{\boldsymbol{x}\in\mathcal{D}} \text{ELBO}(\boldsymbol{\theta}, \boldsymbol{\phi}, \boldsymbol{x})$$

- **Requisito**: Calcular os gradientes $\nabla_{\boldsymbol{\theta},\boldsymbol{\phi}}\text{ELBO}(\boldsymbol{\theta}, \boldsymbol{\phi})$.
- **Problema**: A arquitetura no seu estado atual exige uma etapa de amostragem, o que dificulta a aplicação direta do algoritmo de retropropagação para a adaptação dos parâmetros do encoder (variável aleatória $\boldsymbol{z}$ no caminho da propagação dos gradientes).

# Truque de Reparametrização II




Adaptado de C. M. Bishop e H. Bishop, *Deep Learning: Foundations and Concepts*, Springer Cham, 2024.

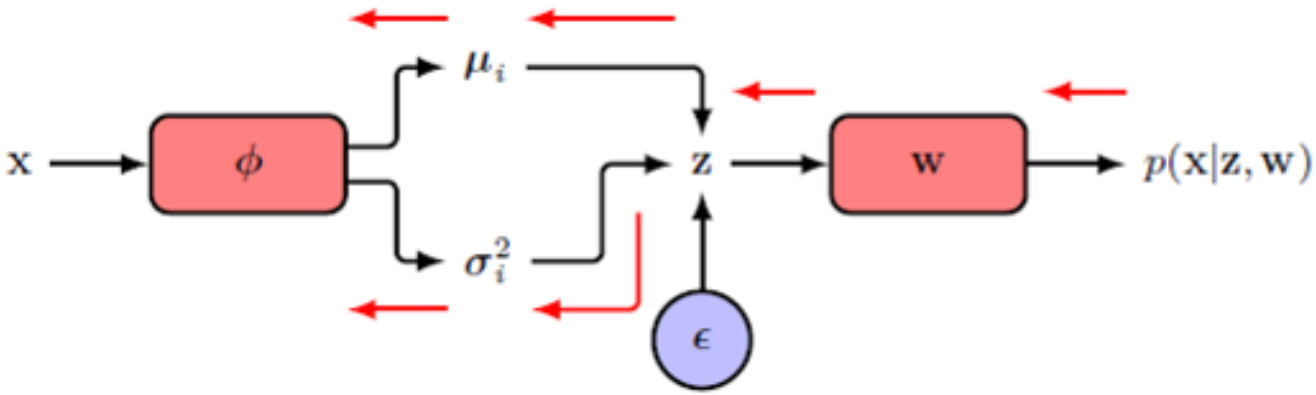
# Truque de Reparametrização III

- **Solução**:
  - Criamos um ramo estocástico na arquitetura da rede neural de modo que as derivadas do algoritmos de retropropagação possam ser calculadas.
  - A ideia do truque de reparametrização é expressar $\boldsymbol{z}$ como uma transformação diferenciável e invertível de outra variável aleatória $\boldsymbol{\epsilon} \sim p(\boldsymbol{\epsilon})$, cuja distribuição é independente de $\boldsymbol{x}$ e $\boldsymbol{\theta}$:

$$\begin{aligned} \boldsymbol{z} &= \boldsymbol{h}(\boldsymbol{\epsilon}, \boldsymbol{\theta}, \boldsymbol{x}) \\ &= \boldsymbol{\mu}_{\boldsymbol{\theta}}(\boldsymbol{x}) + \boldsymbol{\sigma}_{\boldsymbol{\theta}}(\boldsymbol{x}) \odot \boldsymbol{\epsilon}^*, \quad \boldsymbol{\epsilon}^* \sim \mathcal{N}(\mathbf{0}, \boldsymbol{I}) \end{aligned}$$

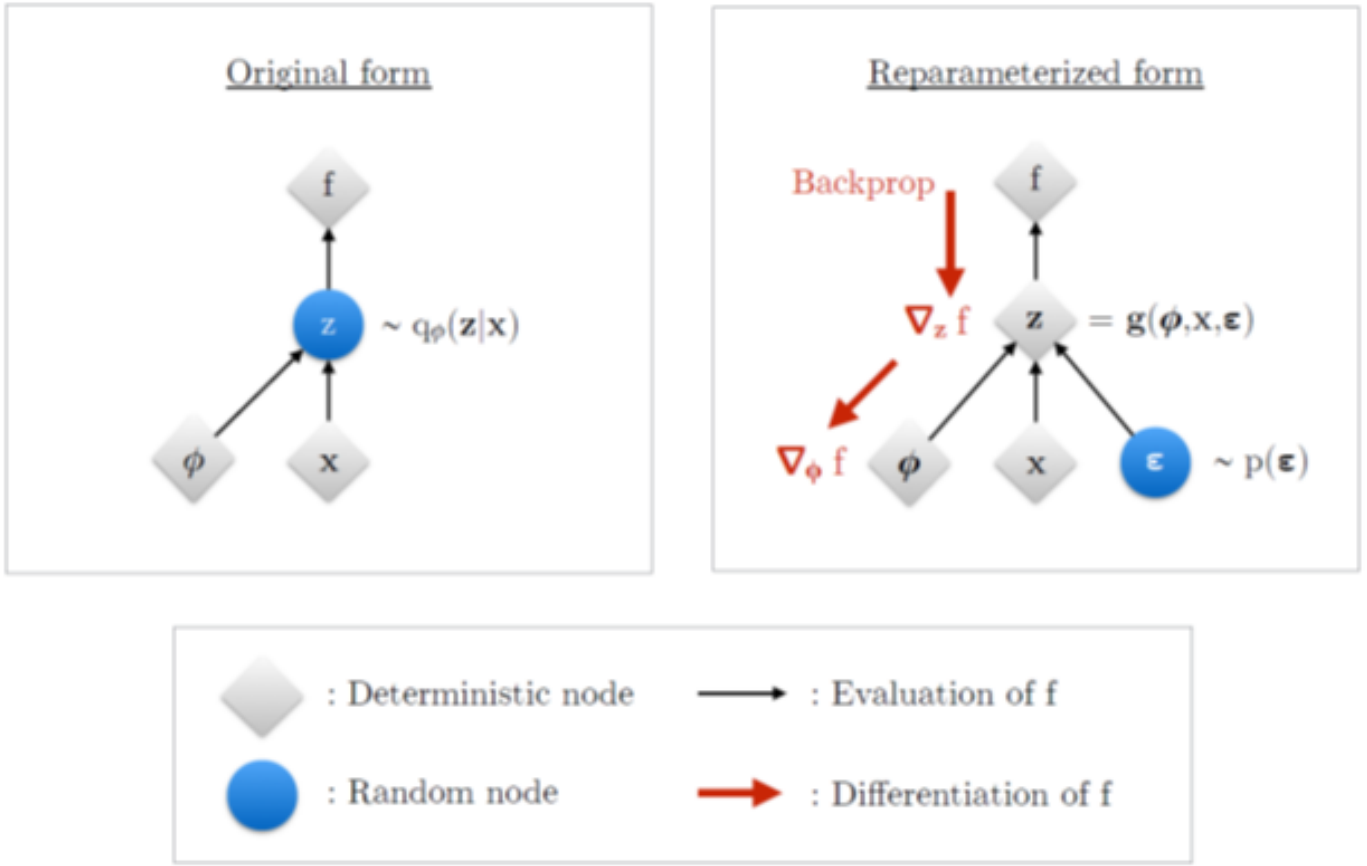
    onde $\odot$ denota o produto Hadamard (produto elemento a elemento).

# Truque de Reparametrização IV




Adaptado de C. M. Bishop e H. Bishop, *Deep Learning: Foundations and Concepts*, Springer Cham, 2024.

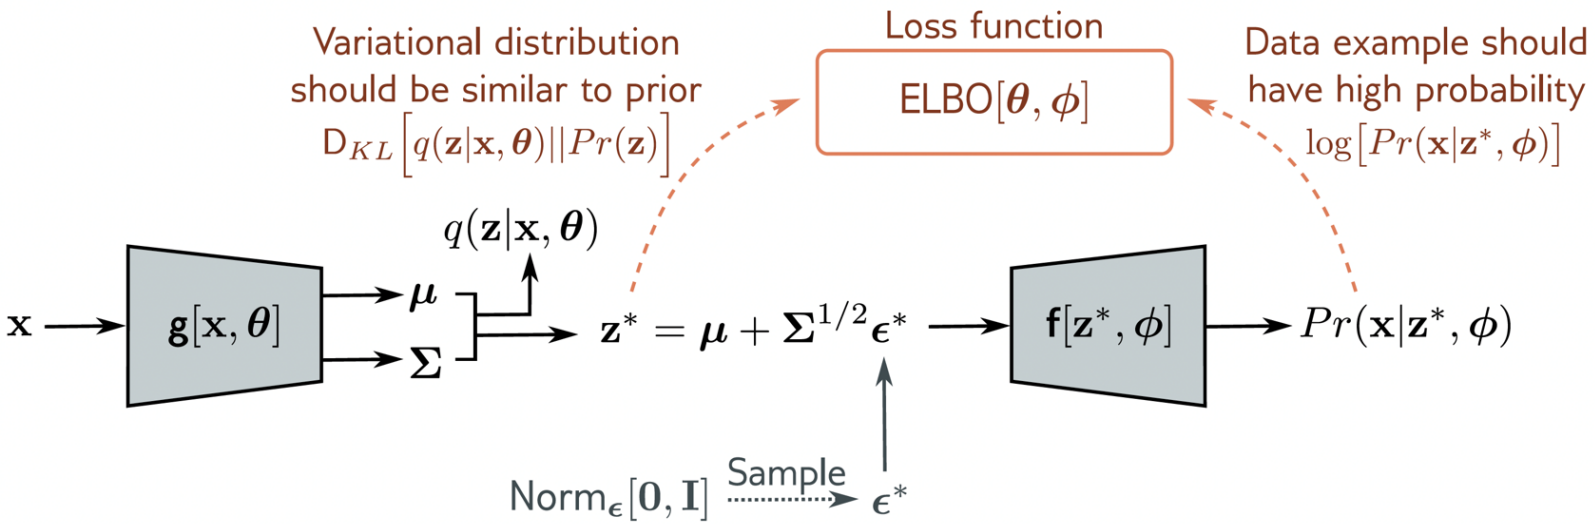
# Truque de Reparametrização V




D. P. Kingma e M. Welling, *An Introduction to Variational Autoencoders*, *Foundations and Trends in Machine Learning*, vol. 12, no. 4, pp. 307–392, Now Publishers, 2019.

# Truque de Reparametrização VI

– Nossa arquitetura neural final do VAE:



# Truque de Reparametrização VII

- Reformulação dos gradientes:

$$\begin{aligned}\nabla_{\boldsymbol{\theta},\boldsymbol{\phi}}\text{ELBO}(\theta,\phi) &= \nabla_{\boldsymbol{\theta},\boldsymbol{\phi}}\left(\mathbb{E}_{q_\theta(\boldsymbol{z}|\boldsymbol{x})}\left[\ln p_\phi(\boldsymbol{x}\mid\boldsymbol{z})\right] - \mathbb{KL}\left(q_\theta(\boldsymbol{z}|\boldsymbol{x})\parallel p(\boldsymbol{z})\right)\right)\\ &= \nabla_{\boldsymbol{\theta},\boldsymbol{\phi}}\mathbb{E}_{\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\boldsymbol{I})}\left[\ln p_\phi(\boldsymbol{x}\mid\boldsymbol{\mu}_{\boldsymbol{\theta}}(\boldsymbol{x})+\sigma_\phi(\boldsymbol{x})\odot\boldsymbol{\epsilon})\right]\\ &\quad - \nabla_{\boldsymbol{\theta},\boldsymbol{\phi}}\mathbb{KL}\left(q_\theta(\boldsymbol{z}|\boldsymbol{x})\parallel p(\boldsymbol{z})\right)\end{aligned}$$

- Gradiente do termo de regularização: pode ser calculado diretamente diferenciando a forma analítica da divergência de KL.

# Truque de Reparametrização VIII

- Gradiente do termo de reconstrução: a expectativa no primeiro termo agora é independente de $\boldsymbol{\theta}$. O método de Monte Carlo pode ser usado sua estimação:

$$\begin{aligned}\nabla_{\boldsymbol{\theta},\boldsymbol{\phi}}\text{ELBO}(\theta,\phi) &= \nabla_{\boldsymbol{\theta},\boldsymbol{\phi}}\mathbb{E}_{\boldsymbol{\epsilon}\sim\mathcal{N}(\mathbf{0},\boldsymbol{I})}\left[\ln p_\phi(\boldsymbol{x}\mid\boldsymbol{\mu}_{\boldsymbol{\theta}}(\boldsymbol{x})+\sigma_\phi(\boldsymbol{x})\odot\boldsymbol{\epsilon})\right]\\ &\approx \frac{1}{L}\sum_{\ell=1}^{L}\nabla_{\boldsymbol{\theta},\boldsymbol{\phi}}\left(\ln p_\phi(\boldsymbol{x}\mid\boldsymbol{\mu}_{\boldsymbol{\theta}}(\boldsymbol{x})+\sigma_\phi(\boldsymbol{x})\odot\boldsymbol{\epsilon}^{(\ell)})\right)\\ &\boldsymbol{\epsilon}^{(\ell)}\sim\mathcal{N}(\mathbf{0},\boldsymbol{I})\end{aligned}$$

# Treinamento I

**Input :** Data set $\mathcal{X}$; `DecoderNet`$_\theta$ and `EncoderNet`$_\phi$
**Result:** Learned parameters $\theta, \phi$

$(\theta, \phi) \longleftarrow$ `initialize`
**while** *Stochastic gradient descent not converged* **do**
  $\mathcal{M} \sim \mathcal{X}$ (sample minibatch of data)
  **for** $\mathbf{x}_i \in \mathcal{M}$ **do**
    $(\boldsymbol{\mu}, \log \boldsymbol{\sigma}^2) \longleftarrow f_\phi(\mathbf{x})$ (encoder)
    $\boldsymbol{\epsilon} \sim \mathcal{N}(0, \boldsymbol{I})$ (sample random noise)
    $\mathbf{z} = \boldsymbol{\mu} + \boldsymbol{\sigma} \odot \boldsymbol{\epsilon}$
    $\mathbf{x}_i' \longleftarrow g_\theta(\mathbf{z})$ (decoder)
    *Compute the loss function from Eqs. (8.13) and (8.14)*
    $\mathcal{L}_i \longleftarrow \log p_\theta(\mathbf{x}_i|\mathbf{z}) + \mathcal{D}_{KL}(\mathcal{N}(\boldsymbol{\mu}, \boldsymbol{\sigma})|\mathcal{N}(0, \boldsymbol{I}))$
  **end**
  *Compute stochastic gradient (using Eq. (8.17))*
  $\nabla_{\theta,\phi}\tilde{\mathcal{L}} = \nabla_{\theta,\phi}\left(\frac{1}{|\mathcal{M}|}\sum_i \mathcal{L}_i\right)$
  *Update network parameters by backpropagation*
  $(\theta, \phi) \longleftarrow$ `Stochastic gradient descent optimizer`
**end**

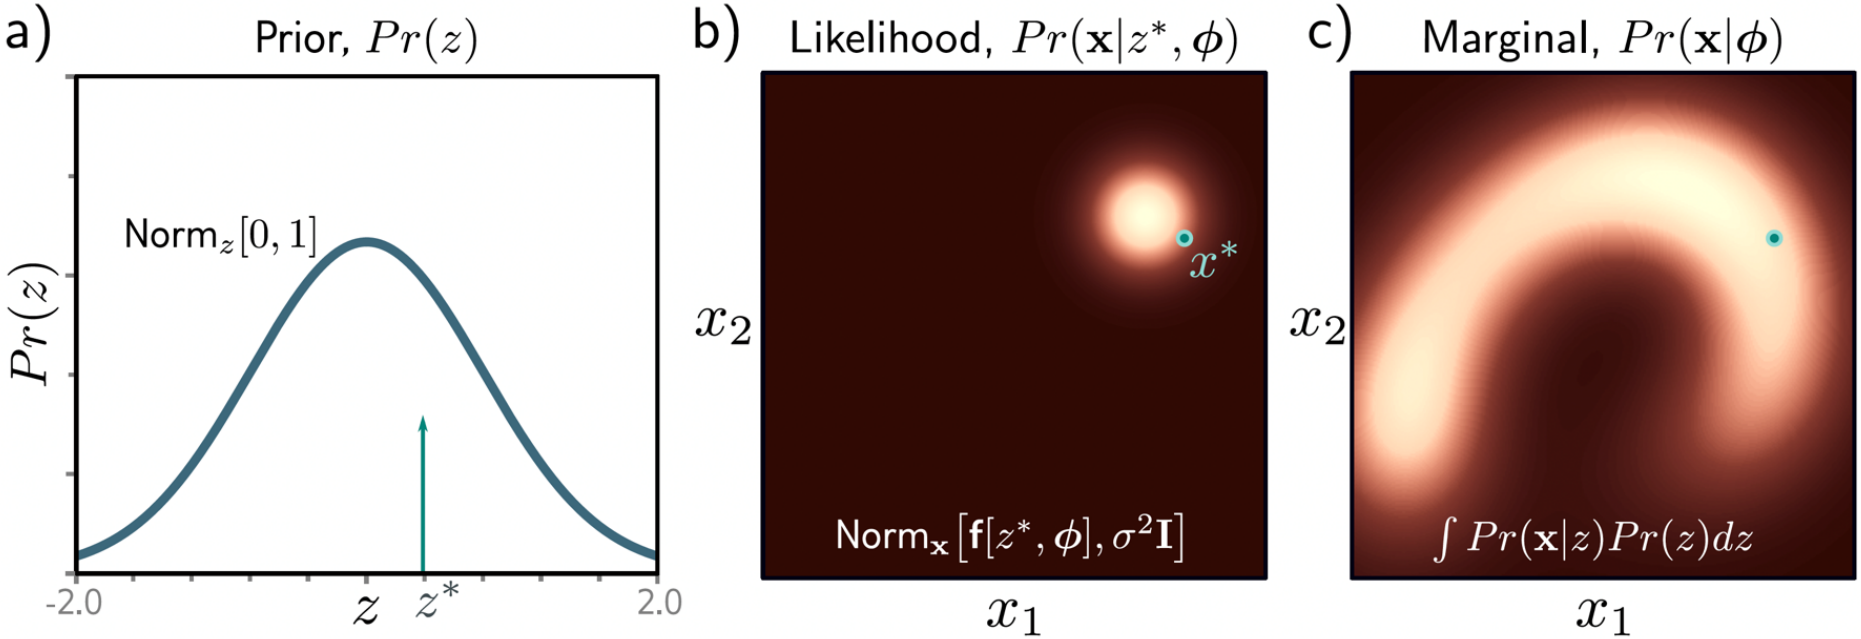
**Algorithm 1:** Training algorithm for variational autoencoders in pseudocode.

J. Ehrhardt e M. Wilms, *Autoencoders and Variational Autoencoders in Medical Image Analysis*, em *Biomedical Image Synthesis and Simulation*, Elsevier, 2022, pp. 129–162.

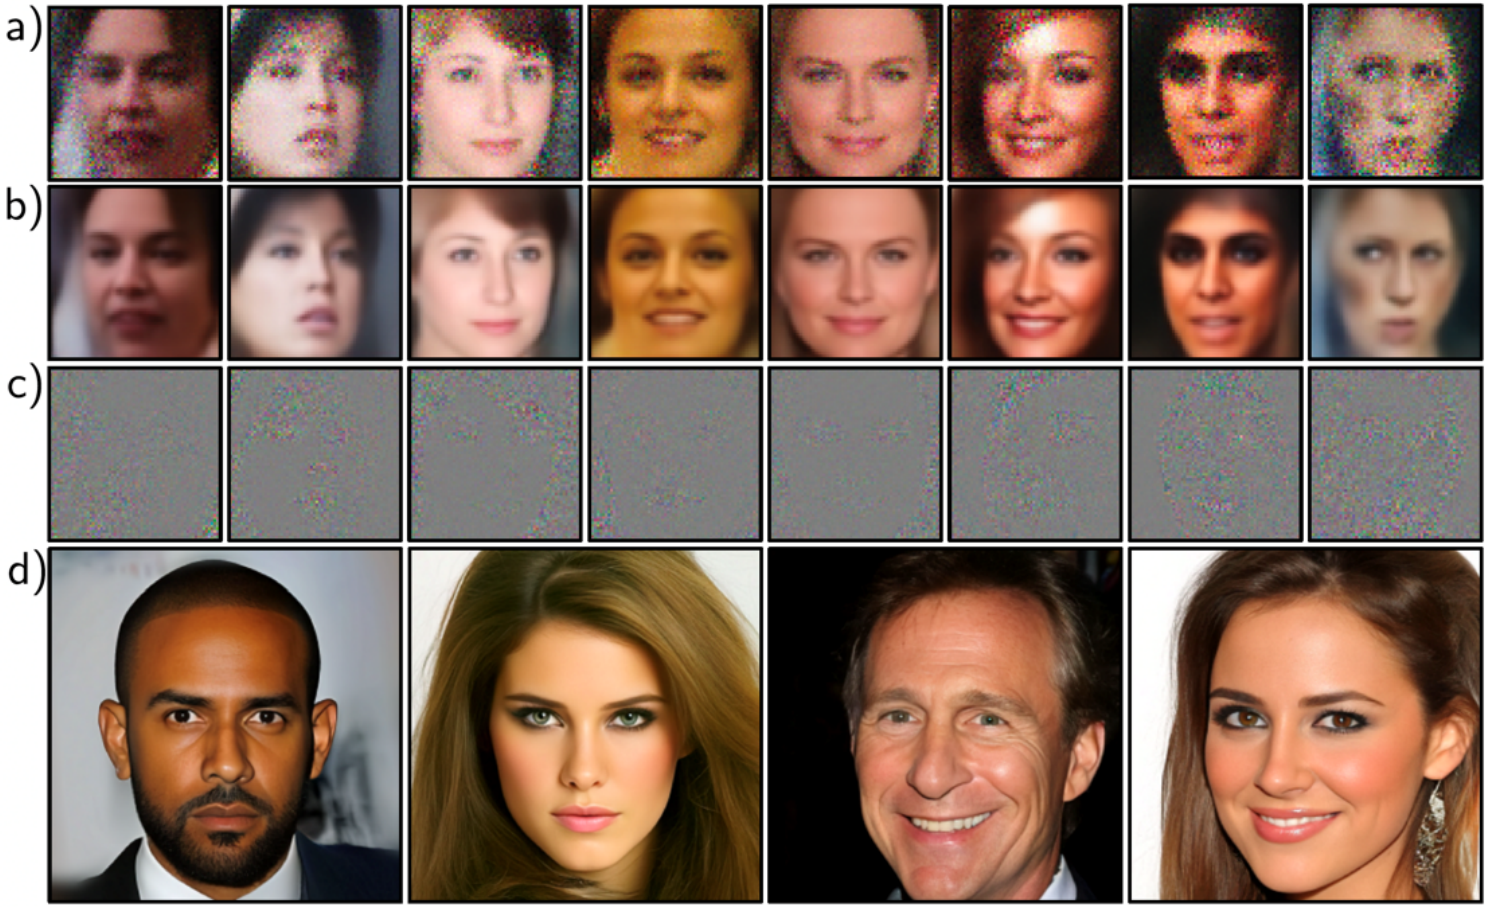
# Geração

A síntese de um novo $\boldsymbol{x}^*$ pode ser feita através da amostragem ancestral:

1. Amostrar $\boldsymbol{z}^*$ de $p(\boldsymbol{z})$;
2. Calcular $f_{\boldsymbol{\phi}}(\boldsymbol{z}^*)$;
3. Amostrar $\boldsymbol{x}^*$ de $p_{\boldsymbol{\phi}}(\boldsymbol{x}|\boldsymbol{z})$;



# Geração



# Aritmética no Espaço Latente I

## Ideia principal

VAEs podem **modificar dados reais** ao projetar um exemplo $\boldsymbol{x}$ no espaço latente, manipular sua representação $\boldsymbol{z}$ e decodificá-la novamente.

1. **Projeção**
   Um dado $\boldsymbol{x}$ é mapeado para o espaço latente:

$$\boldsymbol{z} = \mu_\theta(\boldsymbol{x}) \quad \text{ou} \quad \boldsymbol{z}^* = \arg\max_{\boldsymbol{z}} p(\boldsymbol{z}|\boldsymbol{x})$$

   (pela regra de Bayes $p(\boldsymbol{z}|\boldsymbol{x}) \propto p(\boldsymbol{x}|\boldsymbol{z})\, p(\boldsymbol{z})$).

# Aritmética no Espaço Latente II

2. **Edição no espaço latente**
   - Considere um atributo $i$ (ex.: "usar óculos de sol"). Seja:
     - $\mathcal{X}_i^+$: conjunto de imagens **com** o atributo $i$
     - $\mathcal{X}_i^-$: conjunto de imagens **sem** o atributo $i$
     - $\mathcal{Z}_i^+$: conjunto de vetores latentes correspondentes de $\mathcal{X}_i^+$
     - $\mathcal{Z}_i^-$: conjunto de vetores latentes correspondentes de $\mathcal{X}_i^-$
     - $\bar{\boldsymbol{z}}_i^+$: média dos vetores latentes em $\mathcal{Z}_i^+$
     - $\bar{\boldsymbol{z}}_i^-$: média dos vetores latentes em $\mathcal{Z}_i^-$
   - Definimos o vetor de deslocamento $\Delta \boldsymbol{z}_i$ que representa a direção no espaço latente associada ao atributo $i$:

$$\Delta \boldsymbol{z}_i = \bar{\boldsymbol{z}}_i^+ - \bar{\boldsymbol{z}}_i^-$$

# Aritmética no Espaço Latente III

- Controle da variação de atributos semânticos com **aritmética vetorial** no espaço latente:

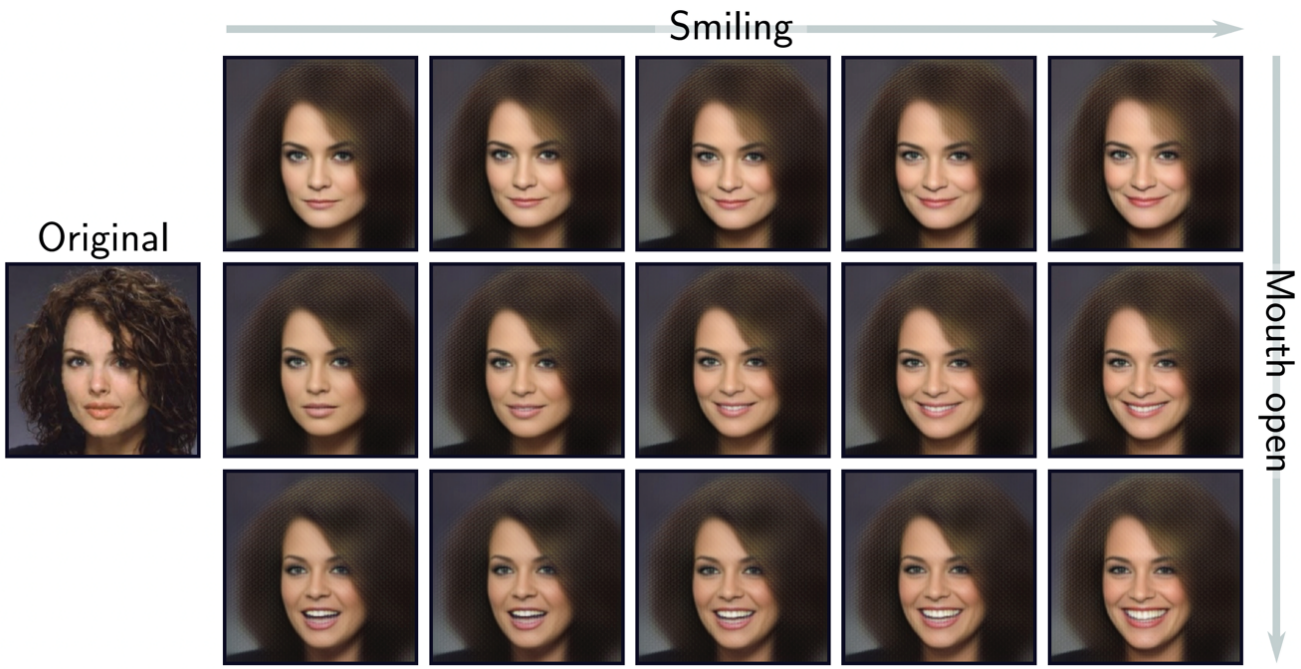
$$\boldsymbol{z}' = \boldsymbol{z} + \alpha \Delta \boldsymbol{z}_i$$

  - $\alpha > 0$: aumenta a intensidade do atributo $i$.
  - $\alpha < 0$: reduz a intensidade do atributo $i$.

3. **Decodificação**
   - O vetor latente editado $\boldsymbol{z}'$ é decodificado, resultando em $\boldsymbol{x}'$, uma versão modificada e plausível de $\boldsymbol{x}$.

# Aritmética no Espaço Latente IV

- Exemplo
  - Atributos “sorriso vs. neutro” e “boca aberta vs. boca fechada”.



# Desentrançamento no Espaço Latente I

- No exemplo da aritmética no espaço latente, as direções que representavam propriedades interpretáveis (sorriso, boca aberta) precisaram ser estimadas com dados rotulados.
- Existem modelos que buscam estruturar o espaço latente de modo que cada dimensão corresponda a propriedades do mundo real.
  - Isso permite manipular um atributo sem afetar os demais.

**Definição**

Um espaço latente é **desentrançado** (*disentangled*) quando cada dimensão representa um fator de variação independente e interpretável do mundo real.

# Desentrançamento no Espaço Latente II

- Exemplos de desentrançamento
  - Imagens de Faces: pose da cabeça, cor do cabelo, expressão facial.
  - Imagens de Cadeiras: rotação, tamanho e tipo de base (giratória vs. fixa).

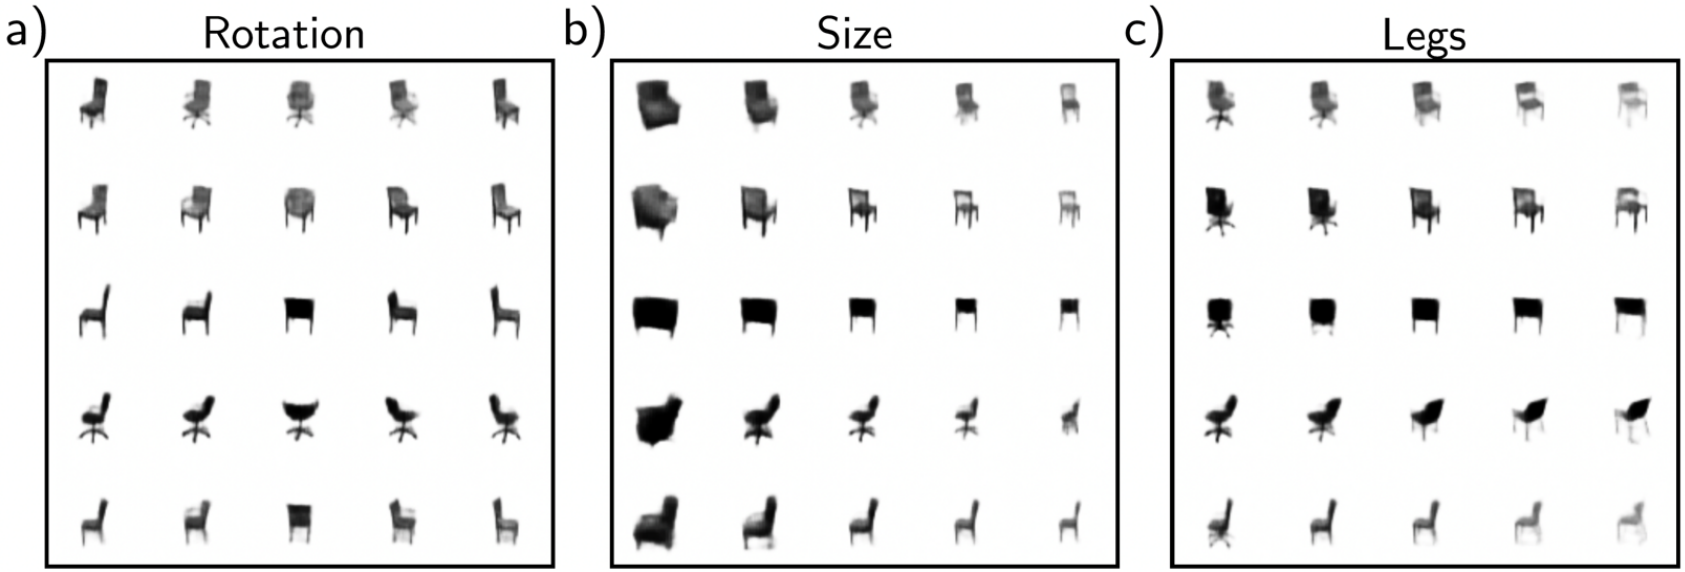



Figura: Desentrançamento obtido com uma variante de VAE revela dimensões latentes com interpretações reais.

# Resumo

Autoencoders variacionais (VAEs) modelam a distribuição dos dados através de:

1. **Limite inferior da evidência**: utilizado para aproximar a função de verossimilhança.
2. **Inferência Variacional:** utilização de um modelo adicional (modelo codificador (*encoder*)) para aproximar as distribuições a posteriori sobre $z$.
3. **Truque de Reparametrização:** utilizado para possibilitar a utilização do algoritmo de retropropagação no treinamento do modelo codificador (*encoder*).

**Limitações**:

- Colapso da distribuição a posteriori.
- Reconstruções borradas.

# Características dos autoencoders variacionais

| | **Autoencoder variacional** |
|---|---|
| Treinamento | estável |
| Verossimilhança | aproximada, rápida |
| Amostragem | rápida |
| Compressão | com perda |
| Representação (espaço latente) | sim |
| Arquitetura | Encoder-Decoder |

# Referências


- Simon J. D. Prince. Understanding Deep Learning, The MIT Press, 2023. [capítulo 17]
  - disponível em: `https://udlbook.github.io/udlbook/`
- Christopher M. Bishop e Hugh Bishop. Deep Learning: Foundations and Concepts, Springer, 2023. [capítulo 19]
  - disponível em: `https://www.bishopbook.com/`
- Kevin P. Murphy. Probabilistic Machine Learning: Advanced Topics, MIT Press, 2023.[capítulo 20]
  - disponível em: `https://probml.github.io/pml-book/book2.html`


Slides construídos com base nos livros supracitados, os quais estão disponibilizados publicamente pelos seus respectivos autores.