

IA Generativa

AutoEncoders

Autoencoders

- Autoencoder (rede neural auto-associativa):
  - Rede neural com entradas e saídas de mesma dimensão
  - Treinada para reproduzir a entrada x na saída $\boxed{y \approx x}$.
  - Objetivo: aprender representações úteis dos dados para aplicações subsequentes.
  - Após o treino, uma camada interna fornece a representação oculta $z(x)$ para a entrada x.
- Arquitetura:
  - Encoder (codificador): $x \rightarrow z(x)$
  - Decoder (decodificador): $z \rightarrow y(z)$

- **Quais restrições podemos impor para evitar soluções triviais?**

Autoencoders

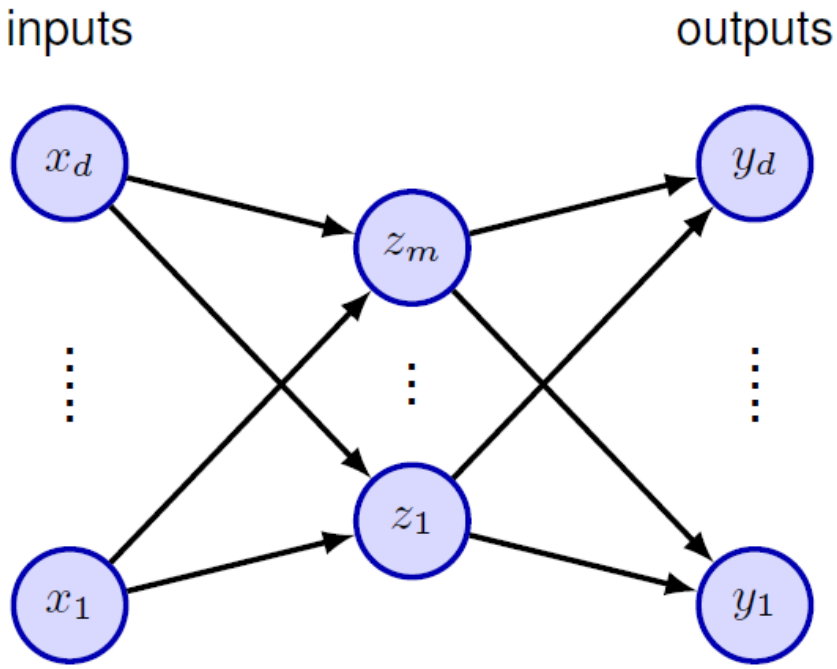
- Para evitar soluções triviais (cópia direta da entrada), impõe-se **restrições:**
  - Reduzir a dimensionalidade de z
  - Forçar esparsidade em z
  - Corromper a entrada x (ruído, dados faltantes)
- Essas restrições forçam o modelo a descobrir estrutura nos dados.
- Generalização para modelos estocásticos:
  - Encoder (codificador): $p(z \mid x)$
  - Decoder (decodificador): $p(y \mid z)$
  - Esses modelos (**generativos**) são chamados *variational autoencoders* (modelagem não linear de variáveis latentes).

Autoencoders Lineares

- Considere uma rede perceptron de múltiplas camadas (MLP):
  - d entradas, d saídas, m unidades ocultas ($m < d$).
  - Vetores de entrada usados como variáveis alvo para as saídas.
- A rede realiza um mapeamento auto-associativo:
  - $m < d$ impede reconstrução perfeita das entradas.
- Função de perda para ajuste dos parâmetros (erro médio quadrático):

$$E(w) = \frac{1}{2}\sum_{n} \|y(x_n, w) - x_n\|^2$$

- A solução de erro mínimo é uma projeção no subespaço das componentes principais (seja com funções de ativação lineares ou não-lineares).

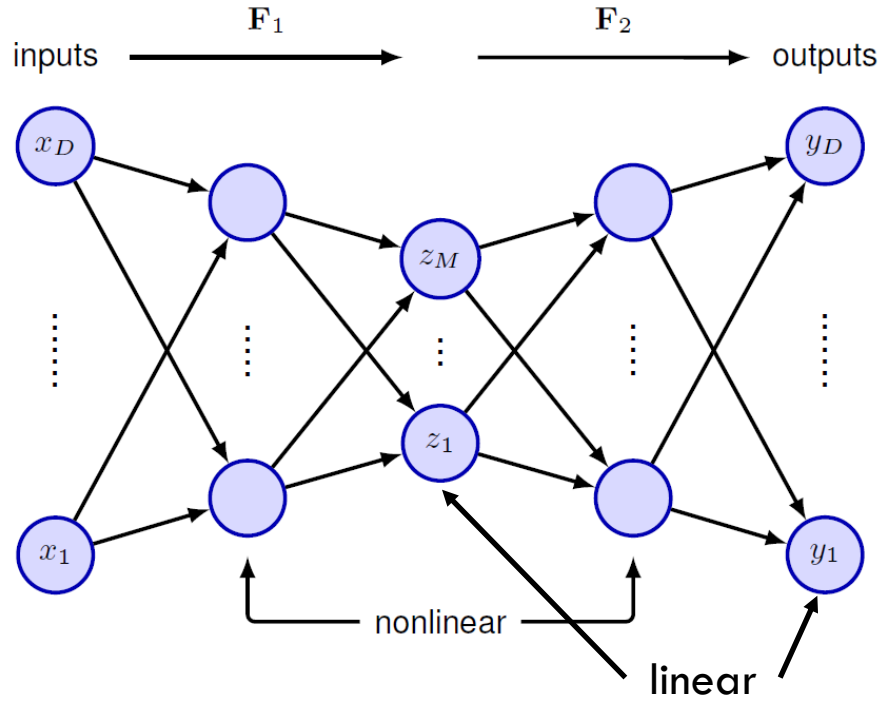


Autoencoders Profundos

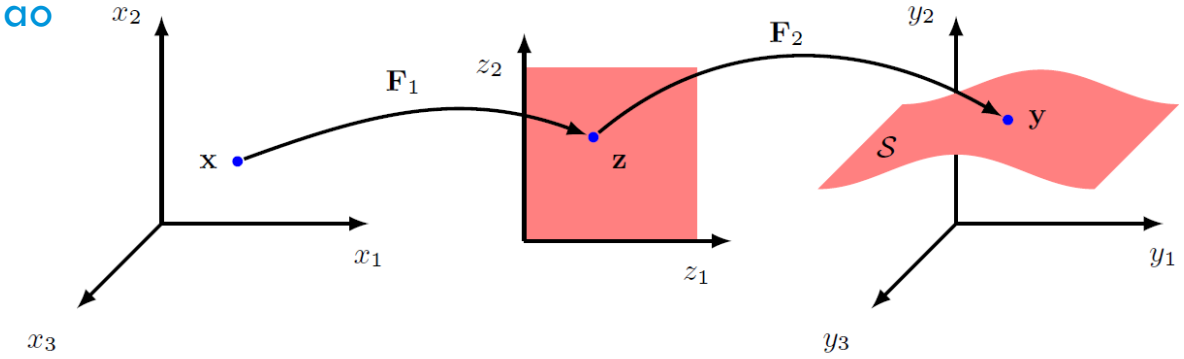
- Rede auto-associativa profunda (múltiplas camadas não-lineares):
- Função de perda para ajuste dos parâmetros:

$$E(w) = \frac{1}{2}\sum_n \|y(x_n, w) - x_n\|^2$$

Exemplo



- Interpretação como dois mapeamentos sucessivos:
  - F_1: projeção dos dados de dimensão D para subespaço S de dimensão M.
  - F_2: mapeamento do subespaço S de dimensão M de volta ao espaço original de dimensão D.
- Treinamento envolve otimização não-linear:
  - Risco de convergência em **mínimos locais**.
  - Dimensionalidade do subespaço S é um hiper-parâmetro.



Autoencoders Esparsos

- Em vez de limitar unidades ocultas, aplica-se regularização que incentiva representações esparsas.
- Função de perda com termo de regularização ℓ_1 sobre as ativações:

$$\tilde{E}(w) = E(w) + \lambda \sum_{k=1}^{K} \|z_k\|_1$$

onde

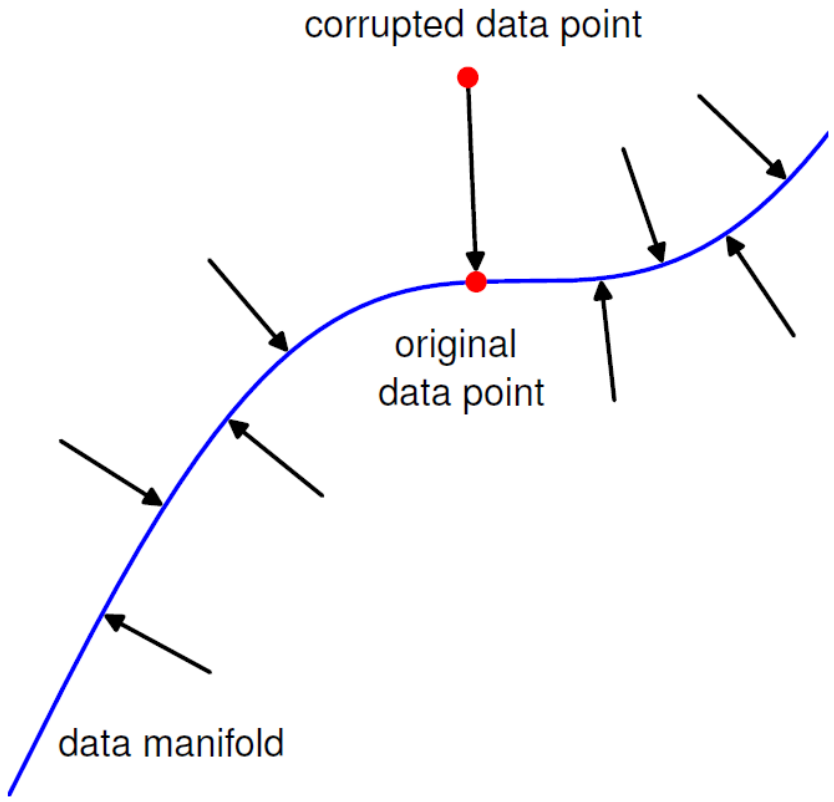
$$E(w) = \frac{1}{2} \sum_{n} \|y(x_n, w) - x_n\|^2$$

- A soma abrange as ativações dos K neurônios de uma camada oculta.
- Regularização incide nas ativações, **não nos parâmetros**, diferindo do uso habitual.

Autoencoder de redução de ruído [*denoising autoencoder*]

- Cada entrada x_n é corrompida por ruído, gerando $\tilde{x}_n$.
- Formas de ruído:
  - Máscara: zera uma fração v de variáveis de entrada ($0 \leq v \leq 1$).
  - Gaussiano: adiciona ruído (independente) de média zero a cada variável. A escala do ruído é dada pela variância da Gaussiana.
- A rede produz $y(\tilde{x}_n, w)$ e é treinada a reconstruir x_n sem ruído.
- Função de perda para treinamento:

$$E(w) = \frac{1}{2}\sum_n \|y(\tilde{x}_n, w) - x_n\|^2$$



- Aprender a remover ruído força a rede a captar estrutura dos dados:
  - Em imagens, correlação entre pixels vizinhos permite corrigir pixels corrompidos.
- Relação com o método *score matching*:
  - A rede aprende a reverter a distorção e consequentemente vetores que apontam para regiões de alta densidade de dados, análogos ao score ($s(x) = \nabla_x \ln p(x)$).

Referências

- Christopher M. Bishop e Hugh Bishop. Deep Learning: Foundations and Concepts, Springer, 2023. [capítulo 19]
  - disponível em: https://www.bishopbook.com/

Slides construídos com base no livro supracitado, os qual está disponibilizados publicamente pelos seus autores.